

# Especificación de Requisitos de Software (ERS)

## ServIA — Avances de Desarrollo

**Versión:** 1.1

**Fecha:** setiembre 2026

**Stakeholder:** Carlos Morales Castro — Director de Gobernanza, MICITT

## 1. Introducción

### 1.1 Propósito

El presente documento constituye la Especificación de Requisitos de Software (ERS) del sistema ServIA. Su propósito es definir de manera clara, verificable y sin ambigüedad los requisitos ya implementados y los que están en desarrollo, estableciendo una línea base de acuerdo entre la Dirección de Gobernanza del MICITT y el estudiante practicante a cargo del proyecto.

Este documento retoma y actualiza el análisis de requerimientos original del sistema JusticIA, elaborado por Yeslin Chinchilla Ruiz y Roger Calderón Urbina (pasantes de la Universidad de Costa Rica, agosto-noviembre 2025), incorporando los módulos y cambios de enfoque desarrollados en la continuación del proyecto como ServIA.

Dicho documento está dirigido a: el tutor y stakeholder principal Carlos Morales Castro, el estudiante practicante, y cualquier persona desarrolladora futura que deba auditar, extender o mantener el sistema.

### 1.2 Ámbito del Sistema

Nombre del sistema: "ServIA" — Asistente de inteligencia artificial gubernamental de propósito general, conducido por la Dirección de Gobernanza del MICITT.

ServIA es una plataforma de ingesta, análisis y consulta conversacional de documentos institucionales mediante inteligencia artificial generativa (RAG). El sistema organiza toda su información bajo la filosofía de "tema": una colección de documentos que un usuario crea y nombra, sin vocabulario ni formato judicial. El sistema permite cargar documentos de texto, audio e imagen, procesarlos, vectorizarlos, y conversar con ellos mediante un asistente que responde citando siempre la fuente. El caso de uso con el que el sistema fue validado inicialmente es la consulta de expedientes judiciales del Poder Judicial de Costa Rica (origen histórico del proyecto, como JusticIA) — el concepto de "expediente" pertenece a ese proyecto original y no es el eje de diseño de ServIA.

El sistema abarca todo el flujo operativo: autenticación y gestión de usuarios; ingesta, extracción, reconocimiento y vectorización de la información; consulta conversacional y presentación de resultados; búsqueda de contenido similar; y bitácora de auditoría.

El sistema NO incluye gestión documental completa de expedientes (eso lo maneja el sistema existente del Poder Judicial), no genera resoluciones judiciales ni sustituye el criterio profesional de los funcionarios, y no ofrece reconocimiento confiable de manuscrito a nivel de producción, ya sea cursivo o de imprenta (ver 2.4, Restricciones).

### 1.3 Definiciones, Acrónimos y Abreviaturas

- ERS: Especificación de Requisitos de Software basada en el estándar IEEE 830-1998.
- RF: Requisito Funcional — describe una función o servicio que el sistema debe proporcionar.
- RNF: Requisito No Funcional — condición o restricción del sistema (rendimiento, seguridad, usabilidad).
- RAG (Retrieval-Augmented Generation): técnica que combina búsqueda de información relevante con generación de texto por un modelo de lenguaje.
- HTR (Handwritten Text Recognition): reconocimiento de texto manuscrito a partir de imágenes.
- OCR (Optical Character Recognition): reconocimiento óptico de caracteres, para texto impreso o tipeado (generado por máquina) en imágenes.
- LLM (Large Language Model): modelo de lenguaje de gran tamaño usado para generar respuestas en lenguaje natural.
- Tema: unidad genérica con la que ServIA organiza y agrupa documentos — no atada a un caso judicial ni a ningún formato institucional específico. Es el eje de diseño del sistema de ahora en adelante.
- Expediente: identificador único de un caso judicial; concepto propio del proyecto original Justicia, con el que el sistema fue validado inicialmente, y que hoy sigue siendo el formato técnico usado internamente para representar un tema del Poder Judicial.
- Notebook (NotebookServIA): colección de documentos genérica que un usuario crea y nombra, con chat propio — implementación concreta del concepto de "tema".
- Embeddings: representación numérica vectorial de un texto, usada para búsqueda semántica.
- Chunk: fragmento en el que se divide un documento antes de vectorizarlo.
- Usuario Gubernamental: funcionario público de cualquier institución del Sector Público que usa el sistema; único tipo de usuario final.
- MICITT: Ministerio de Ciencia, Innovación, Tecnología y Telecomunicaciones de Costa Rica.
- JWT (JSON Web Token): mecanismo de autenticación basado en tokens firmados, usado para proteger la API.
- API REST: interfaz de programación que expone las funciones del backend mediante peticiones HTTP.
- Docker: tecnología de contenedores usada para empaquetar y ejecutar cada servicio del sistema de forma aislada y reproducible.

- Ollama: motor de inferencia local de modelos de lenguaje, usado para correr el LLM sin depender de servicios en la nube.
- Qdrant: motor de base de datos vectorial usado para la búsqueda semántica.
- Celery: sistema de procesamiento asíncrono de tareas en segundo plano (ingesta de documentos).
- Bitácora: registro de auditoría de las acciones relevantes del sistema.

## 1.4 Referencias

- Documento de Análisis de Requerimientos del Sistema Justicia — Dirección de Tecnología de Información del Poder Judicial, agosto 2025.
- Documento de Diseño para el Sistema Justicia — Unidad de Inteligencia de la Información, noviembre 2025.
- Documento de Visión de ServIA — Documentacion\_Proceso/, setiembre 2026.
- Registro\_Indicaciones\_2026 — documentación técnica interna del proyecto ServIA.
- Repositorio del proyecto: [github.com/procmc/Justicia](https://github.com/procmc/Justicia)

## 1.5 Visión General del Documento

Este documento se organiza en cuatro secciones. La sección 1 (Introducción) presenta el propósito del documento, el ámbito del sistema y la terminología utilizada. La sección 2 (Descripción General) expone la perspectiva del producto, sus funciones a alto nivel, el perfil de usuarios, las restricciones y los supuestos y dependencias del proyecto. La sección 3 (Requisitos Específicos) detalla, módulo por módulo, los requisitos funcionales y no funcionales del sistema con su descripción, salida esperada, prioridad y estado de implementación. La sección 4 (Apéndices) recoge referencias complementarias.

# 2. Descripción General

## 2.1 Perspectiva del Producto

ServIA es la continuidad de Justicia. Es un sistema construido como monolito modular — no como arquitectura de microservicios, a diferencia de lo previsto en el análisis de requerimientos original — con backend en FastAPI (Python) y frontend en Next.js (React), orquestado con Docker Compose sobre ocho servicios: backend, celery-worker (procesamiento asíncrono), tika (extracción de texto), redis (cola de tareas), sqlserver (base de datos relacional, local), ollama (modelo de lenguaje local), qdrant (base de datos vectorial) y el servidor de reconocimiento de escritura (HTR).

El sistema funciona en infraestructura 100% local, sin dependencias de servicios de inteligencia artificial en la nube, por la sensibilidad de la información judicial y gubernamental que procesa. Esta es una decisión de diseño distinta de la prevista originalmente (que contemplaba Azure SQL Server y un LLM potencialmente externo); toda la plataforma corre autoalojada.

## 2.2 Funciones del Producto

Las funciones del sistema se agrupan por módulo funcional. Todas están disponibles para el rol Usuario Gubernamental, salvo las de administración, exclusivas del rol Administrador.

### 2.2.1 Seguridad y Acceso

| ID    | Función                    | Descripción                                                                                                                              |
|-------|----------------------------|------------------------------------------------------------------------------------------------------------------------------------------|
| FS-01 | Autenticación              | Inicio de sesión con usuario y contraseña, validados contra la base de datos interna con cifrado.                                        |
| FS-02 | Gestión de roles           | Dos roles: Administrador (gestión de usuarios y bitácora) y Usuario Gubernamental (ingesta, consulta y búsqueda).                        |
| FS-03 | Recuperación de contraseña | Reseteo por administrador o autoservicio por código; el envío de la notificación por correo depende de una cuenta configurada (ver 2.4). |
| FS-04 | Perfil de usuario          | Cada usuario puede configurar un avatar o fotografía de perfil visible en la interfaz.                                                   |

### 2.2.2 Ingesta de Datos

| ID    | Función                        | Descripción                                                                                            |
|-------|--------------------------------|--------------------------------------------------------------------------------------------------------|
| FI-01 | Carga de archivos multiformato | Carga de documentos de texto, audio e imagen (lista completa en 3.2), validando formato y tamaño.      |
| FI-02 | Asociación a un tema           | Cada archivo se vincula obligatoriamente a un tema (hoy implementado como expediente o como notebook). |
| FI-03 | Procesamiento automatizado     | Extracción de texto con Apache Tika; transcripción de audio; reconocimiento de imágenes vía HTR.       |
| FI-04 | Vectorización y almacenamiento | El texto extraído se convierte en embeddings y se indexa en Qdrant para búsqueda semántica.            |

### 2.2.3 Reconocimiento de Escritura (HTR)

| ID    | Función                           | Descripción                                                                                                                                                                               |
|-------|-----------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| FH-01 | Reconocimiento de texto en imagen | Pipeline de detección y reconocimiento (docTR + TrOCR) orientado exclusivamente a texto impreso o tipeado, es decir, generado por una máquina (documento escaneado, captura de pantalla). |

| ID    | Función                                         | Descripción                                                                                                                                                                                                                                                                                       |
|-------|-------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| FH-02 | Limitación de manuscrito, cursivo y de imprenta | El reconocimiento confiable de manuscrito queda fuera de alcance — tanto en letra cursiva como en letra de imprenta (escritura a mano en trazos separados), porque ambas siguen siendo escritas por una persona y varían de una instancia a otra. Documentado como limitación aceptada (ver 2.4). |

#### 2.2.4 Asistente de Consulta (Chat con IA)

| ID    | Función                       | Descripción                                                                                                    |
|-------|-------------------------------|----------------------------------------------------------------------------------------------------------------|
| FA-01 | Interfaz de chat              | Ventana de conversación en lenguaje natural, con historial visible durante la sesión.                          |
| FA-02 | Alcance de consulta           | General (todo el sistema) o acotada a un tema específico (hoy, un expediente o un notebook de NotebookServIA). |
| FA-03 | Respuestas con cita de fuente | Toda respuesta cita el documento del que proviene la información, con reglas anti-alucinación.                 |
| FA-04 | Resúmenes y borradores        | Generación de resúmenes de documentos o temas, y borradores de texto a partir del contenido consultado.        |
| FA-05 | Persistencia del historial    | El historial de conversación se conserva al volver a un tema, sin perderse al recargar la página.              |
| FA-06 | Copiar y reintentar           | Acciones rápidas para copiar la respuesta del asistente o reintentar la misma pregunta.                        |

#### 2.2.5 Búsqueda Híbrida

| ID    | Función                | Descripción                                                                                                                                                                                          |
|-------|------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| FB-01 | Filtro exacto por tema | Si la pregunta menciona un identificador de tema exacto (hoy, un número de expediente judicial), el sistema combina el filtro exacto con la búsqueda semántica en vez de depender solo de similitud. |
| FB-02 | Red de seguridad       | Si el tema detectado no tiene datos, el sistema reintenta la búsqueda sin el filtro en vez de devolver una respuesta vacía.                                                                          |

#### 2.2.6 NotebookServIA

| ID    | Función                  | Descripción                                                                                                     |
|-------|--------------------------|-----------------------------------------------------------------------------------------------------------------|
| FN-01 | Creación de notebooks    | Cualquier Usuario Gubernamental puede crear y nombrar un tema propio (notebook).                                |
| FN-02 | Carga y previsualización | Subida de documentos al notebook, con previsualización del archivo original (imagen o PDF) sin forzar descarga. |

| ID    | Función                   | Descripción                                                                                                |
|-------|---------------------------|------------------------------------------------------------------------------------------------------------|
| FN-03 | Chat acotado al notebook  | Conversación con IA limitada a los documentos de ese tema, con vocabulario genérico.                       |
| FN-04 | Eliminación de documentos | Un documento puede quitarse del notebook (chunks vectoriales, archivo físico y registro en base de datos). |

### 2.2.7 Búsqueda de Temas Similares

| ID    | Función                         | Descripción                                                                                                             |
|-------|---------------------------------|-------------------------------------------------------------------------------------------------------------------------|
| FT-01 | Entrada de criterio de búsqueda | El usuario proporciona un identificador de tema (hoy, un número de expediente) o un fragmento de texto como referencia. |
| FT-02 | Listado de resultados ordenado  | El sistema presenta los temas o documentos más similares, ordenados por grado de coincidencia.                          |

### 2.2.8 Bitácora y Reportes

| ID    | Función                         | Descripción                                                                                                                         |
|-------|---------------------------------|-------------------------------------------------------------------------------------------------------------------------------------|
| FR-01 | Registro automático de acciones | Toda consulta, carga de documento o búsqueda relevante se registra sin intervención manual.                                         |
| FR-02 | Consulta con filtros            | Los administradores pueden filtrar la bitácora por usuario, fecha, tipo de acción y tema asociado.                                  |
| FR-03 | Dashboard de métricas           | Tarjetas de estadísticas, distribución por tipo de acción, actividad diaria reciente, usuarios más activos y temas más consultados. |

## 2.3 Características de los Usuarios

El sistema reconoce dos tipos de actores. El Poder Judicial es hoy el segmento con el que el sistema fue validado inicialmente, pero ambos roles están pensados para cualquier institución del Sector Público.

### 2.3.1 Usuario Gubernamental

| Atributo                   | Descripción                                                                                     |
|----------------------------|-------------------------------------------------------------------------------------------------|
| Nivel de acceso            | Funciones de ingesta, consulta, búsqueda de temas similares y uso de NotebookServIA.            |
| Nivel tecnológico esperado | Básico a intermedio; la interfaz debe ser clara y directa.                                      |
| Dispositivos de uso        | Computadoras de escritorio institucionales, dentro de la red de la institución correspondiente. |

| Atributo          | Descripción                                                                                                                |
|-------------------|----------------------------------------------------------------------------------------------------------------------------|
| Idioma            | Español. El sistema debe estar completamente en español.                                                                   |
| Tipo de necesidad | Consultar y analizar documentos institucionales de forma rápida y verificable, sin exponer información sensible a la nube. |

### 2.3.2 Administrador

| Atributo                     | Descripción                                                                                                                                               |
|------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------|
| Nivel de acceso              | Gestión de usuarios (creación, edición, desactivación lógica) y acceso completo a la bitácora.                                                            |
| Responsabilidades relevantes | Mantener el sistema seguro, revisar la trazabilidad de uso, y resolver manualmente los casos donde el correo de notificación no pueda enviarse (ver 2.4). |

## 2.4 Restricciones

### 2.4.1 Restricciones del Negocio

| ID    | Restricción                    | Descripción                                                                                                           |
|-------|--------------------------------|-----------------------------------------------------------------------------------------------------------------------|
| RN-01 | Conservación de la información | No se permite la eliminación física de registros; la gestión se realiza mediante cambios de estado.                   |
| RN-02 | Inmutabilidad de archivos      | No se puede reemplazar un archivo ya cargado; cualquier cambio requiere cargar un nuevo registro.                     |
| RN-03 | Permisos de ingesta y consulta | Solo el rol Usuario Gubernamental accede a ingesta, consulta y búsqueda; el Administrador no realiza estas funciones. |

### 2.4.2 Restricciones Técnicas

| ID    | Restricción                   | Descripción                                                                                                                                                                   |
|-------|-------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| RT-01 | Formatos de archivo admitidos | Texto: PDF, DOC, DOCX, RTF, TXT, HTML, HTM, XHTML. Audio: MP3, WAV, OGG, M4A. Imagen: JPG, JPEG, PNG, TIF, TIFF, BMP.                                                         |
| RT-02 | Infraestructura 100% local    | El sistema debe ejecutarse sin servicios de inteligencia artificial en la nube, por la sensibilidad de la información que procesa.                                            |
| RT-03 | GPU compartida                | El modelo de lenguaje y el reconocimiento de escritura comparten una GPU con 8 GB de VRAM, un límite estrecho que no permite experimentar libremente con modelos más grandes. |

| ID    | Restricción                                        | Descripción                                                                                                                                                                                                                                                                                                                                                                                                                    |
|-------|----------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| RT-04 | Origen de los modelos de IA                        | Se excluyen modelos de inteligencia artificial de origen chino por restricción institucional, lo que descartó varias opciones viables para reconocimiento de manuscrito.                                                                                                                                                                                                                                                       |
| RT-05 | Reconocimiento de manuscrito cursivo y en imprenta | Queda fuera de alcance con un nivel de confiabilidad de producción: ningún modelo evaluado reconoce de forma confiable escritura a mano —ni cursiva ni de imprenta— dentro de las restricciones de idioma, procesamiento local, GPU y origen. Limitación aceptada del sistema; el enfoque sustituto es el reconocimiento de texto impreso o tipeado generado por máquina (RT-01/FH-01), no de ningún tipo de escritura a mano. |
| RT-06 | Vocabulario del modelo de datos                    | El modelo de datos conserva el concepto de "expediente", propio del proyecto original Justicia, en varias partes del sistema fuera de NotebookServIA. Su generalización completa hacia el concepto de "tema" ya está autorizada y es un objetivo activo del proyecto.                                                                                                                                                          |
| RT-07 | Idioma del sistema                                 | La interfaz y las respuestas del asistente deben estar completamente en español.                                                                                                                                                                                                                                                                                                                                               |

### 2.4.3 Restricciones de Alcance

| ID    | Restricción                   | Descripción                                                                                                                       |
|-------|-------------------------------|-----------------------------------------------------------------------------------------------------------------------------------|
| RA-01 | Equipo de desarrollo reducido | El sistema se desarrolla por un único estudiante practicante dentro del período académico de la Práctica Profesional Supervisada. |
| RA-02 | Sin pruebas automatizadas     | No existe todavía una suite de pruebas automatizadas; la verificación funcional se realiza de forma manual.                       |

## 2.5 Suposiciones y Dependencias

Estas condiciones se asumen verdaderas para que el sistema funcione correctamente. Si alguna falla, el proyecto se ve afectado.

- S-01. Se asume que el tutor (Carlos Morales Castro) participará activamente en la validación de decisiones técnicas e institucionales.
- S-02. Se asume que la Dirección de Gobernanza del MICITT continuará definiendo y ampliando el alcance de uso gubernamental del sistema conforme avance el proyecto.
- S-03. Se asume que el corpus de documentos de prueba seguirá proviniendo de fuentes oficiales autorizadas por la institución.
- S-04. Se asume acceso continuo a la infraestructura de cómputo local necesaria para ejecutar el modelo de lenguaje y el reconocimiento de escritura.

### Dependencias técnicas internas

El asistente de consulta depende de que el motor de lenguaje local (Ollama) y la base de datos vectorial (Qdrant) estén disponibles; una caída de cualquiera de los dos servicios detiene el chat. La ingesta depende del servicio de extracción de texto (Tika) y del worker asíncrono (Celery); si el worker no puede conectarse a la base de datos al arrancar, ningún archivo se procesa hasta reiniciarlo.

### Dependencias de fuentes de datos

Ejecución del plan de ingesta de documentos de interés general para el país. Fuente ya identificada y autorizada por el tutor (Nexus.PJ — jurisprudencia, actas, circulares y avisos del Poder Judicial, 25 de setiembre de 2026); queda como tarea del practicante definir el alcance concreto y ejecutar la carga. Hasta que se ejecute, el asistente sigue respondiendo de forma predominantemente judicial.

Respuesta de la institución universitaria sobre el corpus de manuscrito solicitado para investigación (SPA-Sentences); el afinamiento de reconocimiento de manuscrito depende únicamente de datos sintéticos y muestras propias mientras no se resuelva.

### Dependencias organizacionales

Cuenta de correo institucional o de desarrollo para las notificaciones del sistema (reseteo de contraseña, recuperación por código); mientras no se configure, esas notificaciones no llegan a los usuarios reales.

## 3. Requisitos Específicos

A continuación se detallan los requisitos funcionales y no funcionales del sistema. Cada uno indica su descripción, la salida o criterio esperado, su prioridad y su estado de implementación actual, con el nivel de detalle necesario para evitar ambigüedad en su interpretación.

### 3.1 Requisitos Funcionales

#### Módulo 1: Seguridad y Acceso

---

##### RF-01 — Autenticación de usuarios

**Descripción:** Cuando una persona ingrese su usuario (correo electrónico) y contraseña en la pantalla de inicio de sesión, el sistema deberá validarlos contra la base de datos interna, donde las contraseñas se almacenan cifradas mediante un algoritmo de hash con sal (nunca en texto plano). Si las credenciales son válidas y el usuario está en estado Activo, el sistema genera un token JWT firmado, con un tiempo de expiración definido, que autoriza el acceso a las funciones del rol correspondiente. Si las credenciales son inválidas, el sistema rechaza el acceso con un mensaje de error genérico ("usuario o contraseña incorrectos"), sin indicar cuál de los dos datos fue el incorrecto, para no facilitar ataques de enumeración de usuarios. Un usuario en estado Inactivo no puede autenticarse aunque sus credenciales sean correctas.

**Salida:** Sesión iniciada con token JWT válido y datos del usuario autenticado; o mensaje de error de autenticación sin detalle sobre la causa específica del rechazo.

**Prioridad:** Alta    **Estado:** Implementado

---

## RF-02 — Gestión de roles

**Descripción:** El sistema reconoce exactamente dos roles, sin niveles intermedios: Administrador, con acceso a la gestión de usuarios (creación, edición y desactivación lógica) y a la bitácora completa del sistema; y Usuario Gubernamental, con acceso a ingesta de documentos, consulta conversacional, búsqueda de temas similares y NotebookServIA. Cada endpoint protegido del backend debe verificar el rol del usuario autenticado (a partir del token JWT) antes de ejecutar la acción solicitada, y debe rechazar la solicitud con un código de error de autorización si el rol no corresponde, incluso si el usuario está correctamente autenticado.

**Salida:** Acceso concedido únicamente a las funciones habilitadas para el rol del usuario; rechazo explícito (no un error genérico del servidor) ante cualquier intento de acceder a una función fuera de su rol.

**Prioridad:** Alta    **Estado:** Implementado

---

## RF-03 — Recuperación de contraseña

**Descripción:** El sistema ofrece dos vías: (a) un administrador puede resetear la contraseña de cualquier usuario desde el módulo de gestión de usuarios, generando una contraseña aleatoria de 8 caracteres; y (b) el propio usuario puede solicitar un código de recuperación de 6 dígitos, válido por 15 minutos, enviado a su correo registrado. En ambos casos, el campo de último acceso del usuario se limpia para forzar el cambio de contraseña obligatorio en el siguiente inicio de sesión. Estado actual: no existe una cuenta de correo real configurada en el entorno (ver RT en 2.4), por lo que el envío del correo falla en silencio — la contraseña sí se actualiza en la base de datos, pero la notificación nunca llega al usuario, y el administrador que ejecutó el reseteo no recibe ninguna alerta de que el envío falló. Se acordó con el tutor que el practicante trabaje con una cuenta de correo de desarrollo propia mientras se resuelve el aspecto institucional definitivo, que queda a cargo de Carlos Morales Castro (Director de Gobernanza, MICITT) más adelante. Mientras tanto, el desbloqueo de una cuenta real sigue requiriendo intervención manual directa sobre la base de datos.

**Salida:** Contraseña o código actualizado en la base de datos en todos los casos; correo de notificación entregado al usuario únicamente cuando exista una cuenta de correo configurada.

**Prioridad:** Alta    **Estado:** Parcial

---

## RF-04 — Perfil de usuario (avatar)

**Descripción:** Cada usuario puede seleccionar o cargar una imagen de avatar desde su perfil. El avatar seleccionado se muestra de forma consistente junto al nombre del usuario en toda la interfaz —incluida el área de chat, donde identifica los mensajes enviados por ese usuario— sin necesidad de recargar la página tras el cambio.

**Salida:** Avatar actualizado y visible de inmediato en todos los puntos de la interfaz donde se muestra la identidad del usuario.

**Prioridad:** Baja    **Estado:** **Implementado**

## **Módulo 2: Ingesta de Datos**

---

### **RF-05 — Carga de archivos multiformato**

**Descripción:** El sistema permite cargar archivos de texto (PDF, DOC, DOCX, RTF, TXT, HTML, HTM, XHTML), audio (MP3, WAV, OGG, M4A) e imagen (JPG, JPEG, PNG, TIF, TIFF, BMP). Antes de aceptar la carga, el sistema valida tanto la extensión como el tipo MIME real del archivo (no solo su nombre), y rechaza cualquier formato fuera de esta lista con un mensaje de error que indica los formatos permitidos. El límite de tamaño es de 1GB por archivo, validado de forma consistente tanto en el frontend (para evitar una carga innecesaria) como en el backend (como validación definitiva).

**Salida:** Archivo aceptado, almacenado y encolado para procesamiento asíncrono con un identificador de tarea; o mensaje de error específico indicando si el problema fue el formato, el tamaño, o ambos.

**Prioridad:** Alta    **Estado:** **Implementado**

---

### **RF-06 — Asociación a un tema**

**Descripción:** Todo archivo cargado debe vincularse obligatoriamente a un tema —hoy implementado técnicamente como un expediente (identificador con formato judicial) o como un notebook de NotebookServIA (identificador genérico)— antes de ser aceptado por el sistema. Un archivo nunca queda huérfano: si el tema indicado no existe, el sistema lo crea automáticamente al momento de la carga.

**Salida:** Archivo asociado a su tema correspondiente en la base de datos, recuperable en consultas posteriores acotadas a ese tema.

**Prioridad:** Alta    **Estado:** **Implementado**

---

### **RF-07 — Procesamiento automatizado del contenido**

**Descripción:** El sistema procesa cada archivo de forma asíncrona mediante Celery, según su tipo: los documentos de texto se procesan con Apache Tika para extraer su contenido; el audio se transcribe automáticamente; las imágenes se procesan mediante el pipeline de reconocimiento de escritura (Módulo 3). El estado de cada documento transita entre exactamente tres valores — Pendiente, Procesado o Error — y el progreso del procesamiento (en porcentaje) es visible para el usuario en tiempo real mediante consultas de seguimiento periódicas. Si el procesamiento falla, el documento queda en estado Error con un mensaje descriptivo de la causa, sin bloquear el procesamiento de otros archivos en curso.

**Salida:** Texto extraído del archivo, listo para vectorizar (RF-08); estado del documento actualizado a Procesado, o a Error con detalle de la causa.

**Prioridad:** Alta    **Estado:** **Implementado**

---

### **RF-08 — Vectorización y almacenamiento semántico**

**Descripción:** El texto extraído de cada documento se divide en fragmentos (chunks) de tamaño acotado, preservando el contexto necesario para que cada fragmento sea comprensible de forma independiente. Cada chunk se convierte en un vector numérico (embedding) mediante un modelo de lenguaje multilingüe, y se almacena e indexa en la base de datos vectorial Qdrant junto con sus metadatos (tema de origen, nombre de archivo, tipo de documento, número de página o fragmento), necesarios para que las respuestas del asistente puedan citar la fuente exacta.

**Salida:** Embeddings del documento indexados en Qdrant con sus metadatos completos, disponibles de inmediato para búsqueda semántica y para el asistente de consulta.

**Prioridad:** Alta    **Estado:** **Implementado**

### **Módulo 3: Reconocimiento de Escritura (HTR)**

---

#### **RF-09 — Reconocimiento de texto en imagen**

**Descripción:** Cuando se carga un archivo de imagen, el sistema localiza las líneas de texto mediante un modelo de detección (docTR) y reconoce su contenido mediante un modelo de reconocimiento (TrOCR). Este pipeline está orientado exclusivamente a texto impreso o tipeado generado por una máquina —por ejemplo, una captura de pantalla, un documento impreso fotografiado, o un formulario tipeado escaneado—, donde cada carácter mantiene una forma geométrica consistente entre una instancia y otra.

**Salida:** Texto reconocido de la imagen, integrado al flujo normal de vectorización (RF-08) con la misma trazabilidad de fuente que un documento de texto nativo.

**Prioridad:** Alta    **Estado:** **Implementado**

---

#### **RF-10 — Limitación de reconocimiento de manuscrito (cursivo y de imprenta)**

**Descripción:** El reconocimiento confiable de escritura manuscrita —tanto en letra cursiva (trazos enlazados) como en letra de imprenta (trazos separados, pero seguimos hablando de escritura hecha a mano)— queda fuera de alcance con un nivel de confiabilidad aceptable para producción. La causa no es cursiva contra imprenta: es que cualquier escritura hecha por una persona, sea cual sea su estilo, varía de una instancia a otra en la forma exacta de cada letra, mientras que el texto generado por máquina (RF-09) no varía. Tras una búsqueda exhaustiva de modelos existentes, ninguno satisface simultáneamente las restricciones del proyecto: reconocimiento real de escritura a mano en español, procesamiento 100% local, la GPU compartida de 8GB de VRAM disponible (RT-03), y la exclusión de modelos de origen chino (RT-04).

**Salida:** El sistema documenta esta limitación de forma explícita en la interfaz y en la documentación del proyecto, en vez de ofrecer una funcionalidad de reconocimiento de manuscrito no confiable; el único camino soportado es el de RF-09 (texto generado por máquina).

**Prioridad:** Media    **Estado:** **Limitación aceptada**

### **Módulo 4: Asistente de Consulta (Chat con IA)**

---

### RF-11 — Consulta en lenguaje natural

**Descripción:** El sistema ofrece una interfaz de chat donde el usuario formula preguntas en lenguaje natural, con el alcance de la búsqueda configurable: general (busca en todos los temas a los que el usuario tiene acceso) o acotado a un tema específico. La respuesta se genera de forma incremental (streaming), mostrando el texto a medida que el modelo lo produce en vez de esperar la respuesta completa, para reducir la percepción de espera del usuario.

**Salida:** Respuesta generada por el modelo de lenguaje local (Ollama, llama3.1:8b), mostrada en formato conversacional con streaming en tiempo real.

**Prioridad:** Alta    **Estado:** Implementado

---

### RF-12 — Respuestas con cita de fuente y sin invención de información

**Descripción:** Toda respuesta del asistente debe basarse únicamente en los fragmentos de documentos recuperados para esa consulta específica y citar explícitamente el documento de origen de cada afirmación relevante. El prompt del sistema incluye reglas explícitas contra la invención de nombres de archivo, contenido no presente en el contexto recuperado, o atribución de información a un documento incorrecto. Si la pregunta hace referencia ambigua a un documento (por ejemplo, "el archivo que subí" cuando hay varios), el sistema debe pedir una aclaración en vez de asumir a cuál documento se refiere.

**Salida:** Respuesta con cita de fuente visible junto a cada afirmación relevante; en ausencia de información suficiente en el contexto recuperado, el sistema indica explícitamente que no la tiene, en vez de completarla con conocimiento externo o inventado.

**Prioridad:** Alta    **Estado:** Implementado

---

### RF-13 — Búsqueda híbrida por tema

**Descripción:** Si la pregunta del usuario menciona un identificador de tema de forma exacta y reconocible —hoy, específicamente el formato de número de expediente judicial (año-consecutivo-oficina-materia)—, el sistema detecta esa mención mediante un patrón de texto y combina un filtro exacto de metadata con la búsqueda semántica, en vez de depender solo de similitud sobre toda la base vectorial. Si el tema detectado existe pero no tiene documentos asociados, o el filtro exacto no produce resultados relevantes, el sistema reintenta la búsqueda sin el filtro exacto en vez de devolver una respuesta vacía al usuario.

**Salida:** Resultados acotados exclusivamente al tema detectado cuando existen datos; resultado de búsqueda general, con un aviso claro de que el tema no tenía datos propios, en caso contrario.

**Prioridad:** Alta    **Estado:** Implementado

---

### RF-14 — Persistencia del historial de conversación

**Descripción:** El sistema conserva los mensajes de una conversación —tanto la pregunta del usuario como la respuesta del asistente— al volver a un tema previamente consultado, o al recargar la página dentro de la misma sesión del navegador, en vez de generar una conversación nueva y vacía cada vez. Cada tema

mantiene su propio historial independiente, de forma que cambiar entre varios temas no mezcla ni sobrescribe sus respectivas conversaciones.

**Salida:** Historial completo de mensajes restaurado en la pantalla al volver a un tema, sin pérdida de contexto ni de mensajes previos.

**Prioridad:** Media    **Estado:** **Implementado**

---

#### **RF-15 — Copiar y reintentar respuesta**

**Descripción:** El usuario puede copiar el contenido en texto plano de cualquier respuesta del asistente con un solo clic, sin formato adicional que dificulte su reutilización en otro sistema. Adicionalmente, puede reintentar la misma pregunta si la respuesta obtenida no fue satisfactoria, lo que genera una nueva consulta al asistente sin necesidad de volver a escribir el texto de la pregunta original.

**Salida:** Texto copiado al portapapeles del sistema operativo; o una nueva respuesta generada para la misma pregunta original, reemplazando o agregándose a la anterior según el diseño de la interfaz.

**Prioridad:** Baja    **Estado:** **Implementado**

---

#### **RF-16 — Recuperación ante corte de conexión durante el streaming**

**Descripción:** Si la conexión con el servidor se corta de forma abrupta a mitad de una respuesta en streaming (por ejemplo, por una caída del backend o de la red), el sistema debe detectar la inactividad tras un período de espera definido y liberar automáticamente el control de envío de mensajes, marcando la respuesta interrumpida como tal. Antes de esta funcionalidad, el control de envío quedaba bloqueado de forma indefinida hasta que el usuario recargaba la página manualmente, sin ninguna señal de que el sistema seguía disponible.

**Salida:** Control de envío de mensajes disponible de nuevo tras el período de inactividad definido, sin intervención manual del usuario; mensaje visible de que la respuesta se interrumpió.

**Prioridad:** Media    **Estado:** **Implementado**

---

### **Módulo 5: NotebookServIA**

#### **RF-17 — Creación de notebooks**

**Descripción:** Cualquier Usuario Gubernamental puede crear una colección de documentos propia (notebook), asignarle un nombre descriptivo, y usarla como espacio de trabajo independiente de los demás temas del sistema, sin que el sistema le exija ni le muestre en ningún momento vocabulario o formato judicial. Un usuario puede tener múltiples notebooks activos de forma simultánea.

**Salida:** Notebook creado, disponible de inmediato en la lista de notebooks del usuario, listo para recibir documentos.

**Prioridad:** Alta    **Estado:** **Implementado**

---

#### **RF-18 — Previsualización de archivos originales**

**Descripción:** El usuario puede hacer clic en un documento ya procesado dentro de un notebook y ver su contenido original (imagen o PDF) directamente en el navegador, renderizado en línea sin forzar una descarga al equipo del usuario, con el fin de verificar visualmente el contenido real del documento contra lo que responde el asistente sobre él.

**Salida:** Archivo original mostrado en una ventana de previsualización dentro de la misma interfaz, sin abrir una pestaña ni una descarga separada.

**Prioridad:** Media    **Estado:** Implementado

---

#### RF-19 — Eliminación de documentos del notebook

**Descripción:** El usuario puede quitar un documento de un notebook en cualquier momento. Al hacerlo, el sistema elimina de forma coordinada sus tres representaciones: los fragmentos vectoriales correspondientes en Qdrant, el archivo físico almacenado en disco, y el registro del documento en la base de datos relacional — evitando que quede información huérfana en cualquiera de las tres capas.

**Salida:** Documento eliminado por completo de las tres capas de almacenamiento, sin que vuelva a aparecer en consultas ni en el listado del notebook.

**Prioridad:** Media    **Estado:** Implementado

---

### Módulo 6: Búsqueda de Temas Similares

---

#### RF-20 — Búsqueda por similitud

**Descripción:** El usuario puede iniciar una búsqueda proporcionando un identificador de tema (hoy, un número de expediente) o un fragmento de texto libre como referencia. El sistema compara los vectores del tema o texto de referencia contra el resto de la base vectorial, calculando un puntaje de similitud para cada resultado potencial.

**Salida:** Listado de temas o documentos más similares al de referencia, ordenados de mayor a menor grado de coincidencia, con el porcentaje de similitud visible para cada resultado.

**Prioridad:** Media    **Estado:** Implementado

---

### Módulo 7: Bitácora y Reportes

---

#### RF-21 — Registro automático de acciones

**Descripción:** El sistema registra de forma automática, inmediata y sin intervención manual, cualquier operación significativa realizada por un usuario: consultas al asistente, cargas de archivo y búsquedas de temas similares. Cada registro incluye, como mínimo, el usuario que ejecutó la acción, la fecha y hora exacta, el tipo de acción, y el tema asociado cuando aplique. Los registros de bitácora son inmutables: el sistema no expone ninguna función para editarlos ni eliminarlos.

**Salida:** Un registro de bitácora nuevo e inmutable creado por cada acción relevante, disponible de inmediato para consulta.

**Prioridad:** Alta    **Estado:** **Implementado**

---

#### **RF-22 — Consulta y filtrado de la bitácora**

**Descripción:** Los administradores pueden consultar la bitácora completa del sistema, filtrando los resultados por usuario responsable, rango de fechas, tipo de acción y tema asociado, de forma combinable (varios filtros a la vez).

**Salida:** Listado de registros de bitácora que cumplen simultáneamente todos los criterios de filtro seleccionados.

**Prioridad:** Alta    **Estado:** **Implementado**

---

#### **RF-23 — Dashboard de métricas**

**Descripción:** El sistema presenta, solo para administradores, un panel visual con indicadores clave sobre el uso del sistema: registros del día, eventos de los últimos 30 días, usuarios activos, distribución de acciones por tipo, un gráfico de actividad diaria de los últimos 7 días, los 5 usuarios más activos, los 5 temas más consultados, y la distribución de tipos de archivo cargados.

**Salida:** Panel visual con tarjetas de estadísticas y gráficos, actualizado con datos vigentes al momento de la consulta.

**Prioridad:** Baja    **Estado:** **Implementado**

---

### **3.2 Requisitos No Funcionales**

#### **Eficiencia**

---

##### **RNF-01 — Manejo de solicitudes concurrentes**

**Descripción:** El backend, construido sobre FastAPI de forma asíncrona, debe atender múltiples solicitudes de distintos usuarios de forma concurrente sin bloquear el procesamiento de unas por otras, particularmente durante la generación de respuestas del asistente en streaming, que son operaciones de larga duración.

**Salida:** Tiempos de respuesta que no se degradan de forma perceptible al aumentar el número de usuarios conectados simultáneamente, dentro de la capacidad de la infraestructura local disponible.

**Prioridad:** Alta    **Estado:** **Implementado**

---

##### **RNF-02 — Procesamiento asíncrono de la ingesta**

**Descripción:** La carga de un archivo debe responder de inmediato al usuario (confirmando que la carga fue aceptada) sin esperar a que termine el procesamiento completo, delegando la extracción, el reconocimiento y la vectorización a un worker en segundo plano (Celery), con seguimiento de progreso consultable por el usuario mientras tanto.

**Salida:** Confirmación de carga aceptada en segundos, independientemente de cuánto tarde el procesamiento completo del archivo en segundo plano.

**Prioridad:** Alta    **Estado:** **Implementado**

## Usabilidad

---

### RNF-03 — Interfaz clara y con retroalimentación visible

**Descripción:** La interfaz debe ofrecer flujos claros para las tareas principales (carga de archivos, consulta al asistente, búsqueda de temas similares), con mensajes de retroalimentación explícitos para los estados de éxito, error y validación de datos —nunca dejar una acción sin ninguna respuesta visual para el usuario.

**Salida:** Mensaje visible y comprensible ante cada resultado posible de una acción del usuario (éxito, error específico, validación pendiente).

**Prioridad:** Alta    **Estado:** **Implementado**

---

### RNF-04 — Diseño adaptable (responsive)

**Descripción:** La interfaz debe adaptarse correctamente a distintos tamaños de pantalla, priorizando el uso desde computadoras de escritorio institucionales como caso principal, sin romper su funcionalidad en pantallas más pequeñas.

**Salida:** Interfaz funcional y legible en resoluciones de escritorio estándar, sin elementos superpuestos ni inaccesibles.

**Prioridad:** Media    **Estado:** **Implementado**

## Compatibilidad

---

### RNF-05 — Compatibilidad con navegadores modernos

**Descripción:** El sistema debe funcionar correctamente en los navegadores web modernos de mayor uso institucional (Chrome, Firefox y Edge en sus versiones vigentes), sin depender de funciones exclusivas de un solo navegador.

**Salida:** Funcionalidad completa e idéntica del sistema en cualquiera de los tres navegadores soportados.

**Prioridad:** Alta    **Estado:** **Implementado**

---

### RNF-06 — Despliegue mediante contenedores

**Descripción:** El sistema completo (backend, frontend y todos sus servicios de apoyo) debe poder desplegarse mediante Docker Compose en cualquier equipo que cumpla los requisitos de hardware, sin pasos de instalación manual adicionales más allá de la configuración de variables de entorno.

**Salida:** Los ocho servicios del sistema levantados y comunicándose correctamente entre sí tras ejecutar el comando de despliegue estándar.

**Prioridad:** Alta    **Estado:** Implementado

## Seguridad

---

### RNF-07 — Autenticación y autorización basada en tokens

**Descripción:** Toda comunicación entre el frontend y la API del backend debe ir autenticada mediante un token JWT firmado, con verificación de rol en cada endpoint protegido (ver RF-02). El sistema no debe exponer ninguna función sensible (ingesta, consulta, gestión de usuarios, bitácora) sin autenticación válida.

**Salida:** Rechazo uniforme de cualquier solicitud sin un token JWT válido y vigente, independientemente del endpoint solicitado.

**Prioridad:** Alta    **Estado:** Implementado

---

### RNF-08 — Cifrado de datos sensibles

**Descripción:** Las contraseñas de los usuarios deben almacenarse siempre cifradas mediante un algoritmo de hash con sal, nunca en texto plano ni de forma reversible. La comunicación entre el navegador y el backend debe protegerse mediante HTTPS/TLS en cualquier entorno expuesto más allá de desarrollo local.

**Salida:** Imposibilidad de recuperar una contraseña de usuario en texto plano a partir de la base de datos, incluso con acceso directo a ella.

**Prioridad:** Alta    **Estado:** Implementado

---

### RNF-09 — Procesamiento 100% local de la información

**Descripción:** Ningún documento, consulta ni respuesta del asistente debe transmitirse a un servicio de inteligencia artificial en la nube; todo el procesamiento —extracción, reconocimiento, vectorización, generación de respuestas— debe ejecutarse dentro de la infraestructura local del sistema (ver RT-02).

**Salida:** Cero solicitudes salientes hacia servicios de IA externos durante el uso normal del sistema, verificable por el tráfico de red generado.

**Prioridad:** Alta    **Estado:** Implementado

---

## Disponibilidad y Confiabilidad

---

### RNF-10 — Integridad y no eliminación física de datos

**Descripción:** El sistema no debe ofrecer ninguna función que elimine físicamente un registro de tema, documento, usuario o bitácora; toda gestión de baja se realiza mediante cambios de estado (por ejemplo, Activo/Inactivo), preservando el historial completo para fines de auditoría.

**Salida:** Persistencia permanente de todo registro creado en el sistema, incluso tras ser marcado como inactivo o eliminado desde la perspectiva del usuario.

**Prioridad:** Alta    **Estado:** Implementado

---

## RNF-11 — Recuperación ante fallos de arranque de servicios

**Descripción:** Si un servicio dependiente (como la base de datos relacional) no está disponible en el momento en que otro servicio arranca, este último debe reintentar la conexión de forma automática durante un período razonable, en vez de fallar de forma permanente y requerir un reinicio manual del contenedor.

**Salida:** Recuperación automática del servicio afectado dentro de la ventana de reintento definida, sin intervención manual, cuando la dependencia vuelve a estar disponible.

**Prioridad:** Media    **Estado:** **Implementado**

## 4. Apéndices

Ver también, dentro de Registro\_Indicaciones\_2026: el estado detallado de cada ciclo de la Fase 4 (documentos 22, 25, 28 y 29), y el inventario de debilidades y dependencias abiertas del sistema (documento 26).