

Documento de visión

ServIA — Asistente de Inteligencia Artificial para el Sector Público

Fecha: setiembre 2026

Stakeholder: Carlos Morales Castro — Director de Gobernanza, MICITT

Ubicación: Ministerio de Ciencia, Innovación, Tecnología y Telecomunicaciones (MICITT), Dirección de Gobernanza, San José, Costa Rica

1. Introducción

1.1 Propósito

El presente documento de visión describe el alcance, los objetivos, las partes interesadas y las características generales de ServIA: un asistente de inteligencia artificial pensado para el uso del Sector Público de Costa Rica, bajo la Dirección de Gobernanza del Ministerio de Ciencia, Innovación, Tecnología y Telecomunicaciones (MICITT). El proyecto nació como JusticIA, un desarrollo del Poder Judicial de Costa Rica orientado a la consulta de expedientes judiciales; ese origen histórico dio paso a una visión de gobernanza digital de alcance gubernamental, que hoy conduce el MICITT. Su propósito es establecer una base común de entendimiento entre el estudiante practicante, el tutor y las instituciones involucradas, sirviendo como referencia de alto nivel para la toma de decisiones durante el resto del ciclo de vida del proyecto.

Este documento se elabora en el marco de la Práctica Profesional Supervisada (PPS), hoy bajo la Dirección de Gobernanza del MICITT, y está alineado con la documentación técnica existente del proyecto.

1.2 Alcance

ServIA es una plataforma de ingesta, análisis y consulta conversacional (RAG — Retrieval-Augmented Generation) de documentos institucionales. El sistema permite cargar documentos en distintos formatos (texto, audio, imagen/manuscrito), procesarlos y vectorizarlos, y conversar con ellos mediante un asistente de inteligencia artificial que responde citando siempre la fuente. Incluye además búsqueda de casos similares, gestión de usuarios y una bitácora de auditoría.

La visión del proyecto, definida por la Dirección de Gobernanza del MICITT, es un asistente inteligente para el uso del Sector Público de Costa Rica en general — no de una sola institución. El sistema fue validado inicialmente sobre expedientes judiciales, corpus heredado del origen del proyecto como JusticIA en el Poder Judicial; el sistema incorpora además NotebookServIA, colecciones de documentos genéricas sin vocabulario ni formato judicial, pensadas para que cualquier institución de gobierno pueda usar el mismo motor sobre sus propios documentos.

Estado actual frente a la visión: hoy la información ya ingerida en el sistema corresponde a expedientes judiciales, por lo que el asistente responde predominantemente sobre temas del ámbito judicial. Alcanzar

la visión de un asistente de alcance gubernamental amplio requiere ingerir además documentos de interés general para el país — normativa, trámites, información institucional de otras entidades del Sector Público — de forma que el sistema pueda tratar temas de gobernanza y gobierno en general, más allá de lo judicial. Esta ampliación del corpus es un objetivo explícito del proyecto, no un detalle secundario.

El sistema NO reemplaza el sistema de gestión de expedientes existente del Poder Judicial — ServIA es una capa de análisis y consulta sobre los documentos, no un sistema transaccional de expedientes. Tampoco genera resoluciones judiciales ni sustituye el criterio profesional de los funcionarios: es una herramienta de apoyo. El reconocimiento de manuscrito cursivo con un nivel de confiabilidad de producción queda fuera del alcance funcional actual — es una limitación aceptada del sistema; el alcance de lectura de imágenes se reorienta hacia documentos fotografiados con letra legible en general, no específicamente hacia la escritura cursiva a mano.

1.3 Definiciones, Acrónimos y Abreviaturas

- RAG (Retrieval-Augmented Generation): técnica que combina búsqueda de información relevante con generación de texto por un modelo de lenguaje, para dar respuestas fundamentadas en documentos reales.
- HTR (Handwritten Text Recognition): reconocimiento de texto manuscrito a partir de imágenes.
- OCR (Optical Character Recognition): reconocimiento óptico de caracteres, para texto impreso o legible en imágenes.
- LLM (Large Language Model): modelo de lenguaje de gran tamaño usado para generar respuestas en lenguaje natural.
- Expediente: identificador único de un caso judicial; concepto heredado del Poder Judicial con el que se organizaban los documentos originalmente. Ya no es la filosofía de organización hacia adelante — ver "Tema".
- Tema: unidad genérica con la que ServIA organiza y agrupa documentos de ahora en adelante, en lugar del concepto de "expediente". Un tema no está atado a un caso judicial ni a ningún formato institucional específico, y puede representar cualquier asunto de interés gubernamental (por ejemplo, un área de política pública, un trámite o un proyecto), lo que permite que cualquier institución del Sector Público organice su propia información sin adoptar vocabulario judicial.
- Gobernanza digital: uso coordinado de tecnología e información por parte del Estado para mejorar la gestión pública; mandato de la Dirección de Gobernanza del MICITT.
- Notebook (NotebookServIA): colección de documentos genérica que un usuario crea y nombra, con chat propio, sin vocabulario judicial.
- Embeddings: representación numérica vectorial de un texto, usada para búsqueda semántica.
- Chunk: fragmento en el que se divide un documento antes de vectorizarlo.
- MICITT: Ministerio de Ciencia, Innovación, Tecnología y Telecomunicaciones de Costa Rica.

- PPS: Práctica Profesional Supervisada.
- Docker: tecnología de contenedores usada para empaquetar y ejecutar cada servicio del sistema (backend, base de datos, motor de IA, etc.) de forma aislada y reproducible, tanto en desarrollo como en el despliegue local.
- Ollama: motor de inferencia local de modelos de lenguaje, usado para correr el LLM sin depender de servicios en la nube.
- Qdrant: motor de base de datos vectorial usado para la búsqueda semántica.
- Celery: sistema de procesamiento asíncrono de tareas en segundo plano (ingesta de documentos).
- Bitácora: registro de auditoría de las acciones relevantes del sistema.

1.4 Referencias

- Requerimientos del Sistema de Asistente Judicial con IA (JusticiaIA) — Dirección de Tecnología de Información del Poder Judicial, agosto 2025.
- Documento de Diseño para el Sistema JusticiaIA — Unidad de Inteligencia de la Información, noviembre 2025.
- Registro_Indicaciones_2026 — documentación técnica interna del proyecto ServIA.
- Repositorio del proyecto: github.com/procmc/JusticiaIA

1.5 Visión General del Documento

Este documento se organiza en seis secciones principales. La sección 2 describe el posicionamiento del producto y el problema que resuelve. La sección 3 identifica a las partes interesadas y los usuarios del sistema. La sección 4 presenta una descripción general del producto. La sección 5 detalla las características funcionales del sistema. La sección 6 recoge las restricciones, suposiciones y dependencias que condicionan el desarrollo.

2. Posicionamiento

2.1 Oportunidad de Negocio

JusticiaIA nació en 2025 como proyecto del Poder Judicial de Costa Rica para asistir a funcionarios judiciales en la consulta de expedientes mediante inteligencia artificial generativa, desarrollado por pasantes de la Universidad de Costa Rica. El proyecto evolucionó a ServIA bajo un nuevo mandato: la Dirección de Gobernanza del MICITT asumió su conducción, con una visión de gobernanza digital para el Sector Público de Costa Rica en general, ya no acotada a lo judicial. El sistema conserva el expediente judicial como corpus con el que fue validado inicialmente, pero ese origen ya no define su alcance institucional.

Esta ampliación responde a una necesidad real: las instituciones públicas costarricenses generan grandes volúmenes de documentos que hoy se consultan de forma manual, sin ninguna herramienta común de

inteligencia artificial que respete la confidencialidad de la información institucional. Un sistema que ya demostró ser viable sobre expedientes judiciales, y que puede generalizarse a cualquier institución de gobierno bajo la conducción de la Dirección de Gobernanza del MICITT, representa una oportunidad concreta de eficiencia a escala estatal — siempre que su corpus de documentos se amplíe más allá de lo judicial, de forma que pueda tratar también temas de interés general para el país.

2.2 Definición del Problema

Aspecto	Descripción
El problema es	Las instituciones públicas costarricenses generan grandes volúmenes de documentos (expedientes, actas, circulares, jurisprudencia, informes) difíciles de consultar, resumir y relacionar de forma eficiente.
Que afecta a	Personal de instituciones de gobierno en general —incluidos, entre otros, los funcionarios judiciales— que necesita revisar documentación extensa para tomar decisiones o responder consultas.
El impacto es	Tiempo excesivo dedicado a búsqueda manual de información, dificultad para relacionar documentos similares o precedentes, y procesos de transcripción/digitalización de documentos escaneados lentos y propensos a error.
Una solución exitosa sería	Una plataforma que permita ingerir documentos de distintos formatos, consultarlos en lenguaje natural con respuestas verificables citando la fuente, y encontrar documentos relacionados automáticamente — ejecutándose de forma local, sin exponer información sensible a servicios en la nube.

2.3 Posicionamiento del Producto

Aspecto	Descripción
Para	El Sector Público de Costa Rica en general, bajo la conducción de la Dirección de Gobernanza del MICITT — incluidos los funcionarios del Poder Judicial, corpus con el que el sistema fue validado inicialmente.
Quienes	Necesitan consultar, resumir y relacionar grandes volúmenes de documentos institucionales de forma rápida y confiable.
El producto es	Una plataforma de inteligencia artificial generativa (RAG) para ingesta, análisis y consulta conversacional de documentos gubernamentales, desplegada 100% en infraestructura local.
Que	Permite subir documentos de texto, audio y de imagen; conversar con ellos mediante un asistente de IA que cita sus fuentes; buscar casos similares; y organizarlos en colecciones propias (notebooks) sin necesidad de vocabulario judicial.

Aspecto	Descripción
A diferencia de	Herramientas de IA generativa en la nube (asistentes comerciales genéricos), que no garantizan la confidencialidad de información sensible ni pueden desplegarse dentro de la infraestructura institucional.
Nuestro producto	Procesa toda la información de forma local (Ollama, Qdrant, SQL Server autoalojados), sin enviar datos a terceros, cumpliendo con los requisitos de confidencialidad de la información judicial y gubernamental.

3. Descripción de las Partes Interesadas y Usuarios

3.1 Resumen de las Partes Interesadas

Nombre	Descripción	Responsabilidades
Carlos Morales Castro	Director de Gobernanza, MICITT; tutor del proyecto.	Definir alcance y prioridades, validar decisiones técnicas e institucionales, autorizar el uso de fuentes de datos y coordinar con las demás instituciones involucradas.
MICITT — Dirección de Gobernanza	Institución que conduce el proyecto ServIA.	Definir el alcance de gobernanza digital del sistema, proveer los requerimientos institucionales, y coordinar su despliegue hacia el Sector Público de Costa Rica.
Andrés Josué Araya Agüero	Estudiante practicante, desarrollador principal del proyecto ServIA.	Diseño, desarrollo, pruebas y documentación del sistema; investigación técnica; reporte de avance semanal.
Equipo de desarrollo original (Justicia)	Yeslin Chinchilla Ruiz y Roger Calderón Urbina, pasantes de la Universidad de Costa Rica.	Construcción del backend y frontend inicial: módulos de seguridad, ingesta, asistente de consulta y búsqueda de casos similares.
Poder Judicial de Costa Rica	Institución de origen del proyecto (Justicia, 2025); ya no es cliente ni parte interesada activa.	Ninguna activa. Su corpus de expedientes judiciales sigue siendo la base con la que el sistema fue validado inicialmente.
Usuario Gubernamental	Funcionario público que consulta el sistema en su trabajo diario, en cualquier institución del Sector Público (Poder Judicial, MICITT, INDER, CCSS, Fuerza Pública, MEP, entre otras). El Poder Judicial es hoy el segmento con el que el sistema fue validado inicialmente.	Usar el asistente de consulta, la ingesta de documentos y la búsqueda de casos similares.

3.2 Resumen de Usuarios

Nombre	Descripción	Responsabilidades	Criterios de éxito
Usuario Gubernamental	Funcionario público de cualquier institución del Sector Público que consulta documentos mediante el asistente de IA. Hoy validado con usuarios del Poder Judicial. Es un único tipo de usuario: una vez inicia sesión, tiene acceso a todas las herramientas del sistema, incluida NotebookServIA (crear sus propias colecciones de documentos y conversar con ellas) — no es un rol aparte.	Realizar consultas en lenguaje natural, cargar documentos, buscar casos similares, y crear y usar sus propios notebooks en NotebookServIA.	Obtener respuestas correctas y verificables, con cita de fuente, en menos tiempo que la revisión manual; y un asistente de IA útil sobre sus propios documentos, sin fricción de configuración.
Administrador	Usuario con privilegios de gestión del sistema.	Administrar cuentas de usuario y roles; revisar la bitácora de auditoría.	Mantener el sistema seguro, con trazabilidad completa de su uso.

3.3 Entorno de Usuario

Los usuarios acceden al sistema desde computadoras institucionales, hoy principalmente dentro de la red del Poder Judicial (corpus con el que el sistema fue validado) y, conforme avance el plan de gobernanza digital del MICITT, de otras instituciones del Sector Público. El sistema es una aplicación web (Next.js) accesible desde navegadores modernos, en idioma español. Dado el carácter sensible de la información judicial y gubernamental, el sistema corre en infraestructura 100% local (Docker), sin dependencias de servicios de inteligencia artificial en la nube — lo que impone restricciones de hardware, en particular una GPU compartida entre el modelo de lenguaje y el módulo de reconocimiento de escritura.

3.4 Necesidades Clave de las Partes Interesadas

Parte interesada	Necesidad	Solución propuesta
MICITT (Dirección de Gobernanza)	Que la herramienta sirva a cualquier institución del Sector Público, no solo al Poder Judicial.	NotebookServIA: colecciones de documentos genéricas, sin vocabulario ni formato judicial forzado.
MICITT (Dirección de Gobernanza)	Que el corpus de conocimiento del asistente refleje temas de gobierno en general, no solo judiciales.	Ampliación del corpus con documentos de interés general para el país (ver 1.2 y 6.1/6.3).

Parte interesada	Necesidad	Solución propuesta
Usuario Gubernamental	Consultar documentos de su institución de forma rápida y confiable, sin exponer datos sensibles a la nube.	Chat con IA (RAG) 100% local, con citas de fuente, sobre documentos vectorizados.
Usuario Gubernamental	Evitar que el asistente invente información o alucine contenido de documentos.	Prompt con reglas anti-alucinación, citas obligatorias, y reformulación de preguntas ambiguas.
Usuario Gubernamental	Digitalizar documentos escaneados o fotografiados y facilitar su consulta.	Pipeline de reconocimiento orientado a texto impreso o tipeado capturado por imagen (letras de forma consistente y bien separadas, como una fotografía de pantalla o un documento impreso escaneado). El manuscrito cursivo queda fuera de este enfoque: no se encontró, tras una búsqueda exhaustiva, ningún modelo que reconozca manuscrito real en español dentro de las restricciones del proyecto (procesamiento local, GPU compartida, licencia compatible), por lo que se documenta como limitación aceptada del sistema en lugar de seguir invirtiendo esfuerzo en resolverlo.
Administradores	Trazabilidad de todas las acciones del sistema.	Módulo de bitácora con registro de consultas, cargas y búsquedas, filtrable por usuario, fecha y tipo de acción.

4. Descripción General del Producto

4.1 Perspectiva del Producto

ServIA es la continuidad de JusticIA: un sistema construido como monolito modular, con backend en FastAPI y frontend en Next.js, orquestado con Docker Compose sobre ocho servicios — backend, celery-worker (procesamiento asíncrono), tika (extracción de texto), redis (cola de tareas), sqlserver (base de datos relacional), ollama (modelo de lenguaje local), qdrant (base de datos vectorial) y el servidor de reconocimiento de escritura. El sistema reutiliza la infraestructura ya construida para JusticIA, extendiéndola con NotebookServIA como capa de uso genérico, sin reemplazar el modelo de datos ni el flujo de ingesta ya existente.

4.2 Resumen de Capacidades del Producto

Capacidad	Descripción
Ingesta de documentos	Carga de archivos de texto (PDF, DOC, DOCX, RTF, TXT, HTML), audio y de imagen, asociados a un expediente o a un notebook.

Capacidad	Descripción
Extracción y transcripción	Extracción de texto de documentos, transcripción de audio, y reconocimiento de imágenes de texto legible.
Vectorización y búsqueda semántica	Los documentos se convierten en representaciones numéricas y se almacenan en una base de datos vectorial, con búsqueda híbrida (semántica y por filtro exacto).
Asistente de consulta (chat con IA)	Conversación en lenguaje natural sobre expedientes o notebooks, con un modelo de lenguaje local, y respuestas que citan siempre su fuente.
NotebookServIA	Colecciones de documentos genéricas, para cualquier institución o propósito, con su propio chat y vocabulario neutro.
Búsqueda de casos similares	Localizar expedientes o documentos con similitud temática.
Gestión de usuarios y seguridad	Autenticación, roles de Administrador y Usuario Gubernamental, y recuperación de contraseña.
Bitácora de auditoría	Registro de todas las consultas, cargas y búsquedas relevantes, con filtros para administradores.

4.3 Licencias y Restricciones de Instalación

El sistema se desarrolla en el marco de una Práctica Profesional Supervisada, bajo dirección de la Dirección de Gobernanza del MICITT. Las tecnologías empleadas son de código abierto o de uso libre; se evita explícitamente el uso de modelos de inteligencia artificial de origen o licencia no verificable. El despliegue es 100% local, sin dependencias de servicios de inteligencia artificial en la nube, dado el carácter sensible de la información judicial y gubernamental. La titularidad del código corresponde al MICITT.

5. Características del Producto

A continuación se describen las características funcionales del sistema de forma resumida.

5.1 Ingesta de Documentos Multiformato

El sistema permite cargar documentos en los siguientes formatos, asociándolos a un expediente o a un notebook genérico:

- Texto: PDF, DOC, DOCX, RTF, TXT, HTML, HTM, XHTML.
- Audio: MP3, WAV, OGG, M4A.
- Imagen: JPG, JPEG, PNG, TIF, TIFF, BMP.

La carga se procesa de forma asíncrona, con seguimiento de progreso visible para el usuario.

5.2 Reconocimiento de Documentos Escaneados

Los documentos capturados por imagen se procesan mediante un pipeline de reconocimiento de texto, orientado a texto impreso o tipeado — por ejemplo, capturas de pantalla o documentos escaneados, donde cada letra mantiene una forma consistente y las letras están bien separadas entre sí. El manuscrito cursivo es un problema distinto: la forma de una misma letra cambia con cada persona que escribe, por lo que el modelo tiene que "adivinar" mucho más para reconocerla. Tras una investigación exhaustiva no se encontró ningún modelo que reconozca manuscrito real en español dentro de las restricciones del proyecto (procesamiento 100% local, GPU compartida, licencia compatible con uso gubernamental), por lo que el reconocimiento confiable de manuscrito cursivo queda fuera del alcance actual del sistema y se documenta como una limitación conocida — el texto impreso o tipeado capturado por imagen es el enfoque que sí se sostiene.

5.3 Asistente de Consulta Conversacional

Un asistente de inteligencia artificial permite conversar en lenguaje natural sobre los documentos ingeridos, ya sea de forma general, acotada a un expediente específico, o acotada a un notebook. Las respuestas citan siempre la fuente del documento consultado, con reglas explícitas contra la invención de información.

5.4 Búsqueda Híbrida

El sistema combina búsqueda semántica (por significado) con filtrado exacto por expediente, de forma que las consultas sobre un caso específico solo consideran los documentos de ese caso, sin mezclar información de otros expedientes.

5.5 NotebookServIA — Colecciones de Documentos Genéricas

Cualquier usuario puede crear una colección de documentos propia (notebook), nombrarla y conversar con ella, organizada bajo la filosofía de temas del sistema — genérica, sin vocabulario ni formato judicial. Es el mecanismo con el que cualquier institución del Sector Público organiza y consulta sus propios documentos, tal como lo requiere un proyecto de alcance gubernamental.

5.6 Búsqueda de Casos Similares

El sistema permite localizar expedientes o documentos con similitud temática o jurídica respecto a un caso de referencia, apoyando la identificación de precedentes.

5.7 Gestión de Usuarios y Seguridad

El sistema cuenta con autenticación de usuarios, dos roles (Administrador y Usuario Gubernamental) y recuperación de contraseña. El acceso administrativo permite gestionar cuentas y consultar la bitácora de auditoría.

5.8 Bitácora de Auditoría

Toda consulta, carga de documentos o búsqueda relevante queda registrada, con filtros por usuario, fecha, tipo de acción y expediente asociado, para fines de trazabilidad y auditoría institucional.

6. Restricciones, Suposiciones y Dependencias

6.1 Restricciones del Sistema

- El sistema debe ejecutarse 100% en infraestructura local, sin servicios de inteligencia artificial en la nube, por la sensibilidad de la información judicial y gubernamental.
- El reconocimiento de manuscrito cursivo con un nivel de confiabilidad de producción queda fuera de alcance: tras una búsqueda exhaustiva de modelos existentes, ninguno satisface simultáneamente las restricciones del proyecto. Dos de esas restricciones son especialmente determinantes: (1) la GPU disponible es compartida entre el modelo de lenguaje y el reconocimiento de escritura, con 8GB de memoria — un límite estrecho que no permite experimentar libremente con modelos más grandes; y (2) se excluyen modelos de origen chino por restricción institucional, lo que descartó varias opciones que sí reconocían manuscrito en español pero no cumplían este requisito de origen. Se documenta como limitación aceptada del sistema (decisión conjunta con el tutor, 25 de setiembre de 2026); el enfoque sustituto es el reconocimiento de texto impreso o tipeado capturado por imagen, donde la forma de cada letra es consistente en vez de variar con cada persona que escribe.
- El modelo de datos conserva vocabulario judicial en varias partes del sistema fuera de NotebookServIA. Su generalización completa hacia un vocabulario gubernamental neutro ya está autorizada por el tutor (confirmado con el cambio institucional del 25 de setiembre de 2026) y es un objetivo activo del proyecto — el sistema debe entrenarse y ajustarse a nivel general para responder con enfoque gubernamental, sin quedar limitado a respuestas de carácter judicial.
- El proyecto se desarrolla por un único estudiante practicante dentro del período académico de la Práctica Profesional Supervisada, lo que acota el alcance a las prioridades definidas con el tutor.
- No existe todavía una suite de pruebas automatizadas; la verificación funcional se realiza de forma manual.

6.2 Suposiciones

- Se asume que el tutor (Carlos Morales Castro) participará activamente en la validación de decisiones técnicas e institucionales.
- Se asume que la Dirección de Gobernanza del MICITT continuará definiendo y ampliando el alcance de uso gubernamental del sistema conforme avance el proyecto.
- Se asume que el corpus de documentos de prueba seguirá proviniendo de fuentes oficiales autorizadas por la institución.

- Se asume acceso continuo a la infraestructura de cómputo local necesaria para ejecutar el modelo de lenguaje y el reconocimiento de escritura.

6.3 Dependencias Críticas

ID	Dependencia	Impacto si no se resuelve
D-01	Ejecución de la generalización del modelo de datos, hoy 100% judicial fuera de NotebookServIA. Autorización ya confirmada por el tutor; queda como tarea de planificación y desarrollo definir el alcance del cambio y ejecutarlo, dado que toca casi todo el sistema.	Hasta que se ejecute, el sistema sigue forzando vocabulario judicial en el chat general, limitando su adopción por otras instituciones de gobierno.
D-02	Respuesta de la institución universitaria sobre el corpus de manuscrito solicitado para investigación.	El afinamiento de reconocimiento de manuscrito depende únicamente de datos sintéticos y muestras propias, insuficientes para un uso de producción.
D-03	Cuenta de correo institucional o de desarrollo para las notificaciones del sistema.	El reseteo de contraseña y la recuperación de cuenta por código siguen sin enviar notificaciones reales a los usuarios.
D-04	Ejecución del plan de ingesta de documentos de interés general para el país. Fuente ya identificada y autorizada por el tutor (Nexus.PJ — jurisprudencia, actas, circulares y avisos del Poder Judicial, 25 de setiembre de 2026); queda como tarea del practicante definir el alcance concreto (qué tipos de documento y volumen) y ejecutar la carga.	Hasta que se ejecute, el asistente sigue respondiendo de forma predominantemente judicial, sin poder tratar temas gubernamentales más amplios — el punto central para cumplir la visión del sistema.