

Especificación de Requisitos de Software (ERS)

ServIA — Avances de Desarrollo

Versión: 1.4

Fecha: octubre 2026

Stakeholder: Carlos Morales Castro — Director de Gobernanza, MICITT

1. Introducción

1.1 Propósito

El presente documento constituye la Especificación de Requisitos de Software (ERS) del sistema ServIA. Su propósito es definir de manera clara, verificable y sin ambigüedad los requisitos ya implementados y los que están en desarrollo, estableciendo una línea base de acuerdo entre la Dirección de Gobernanza del MICITT y el estudiante practicante a cargo del proyecto.

Este documento retoma y actualiza el análisis de requerimientos original del sistema JusticIA, elaborado por Yeslin Chinchilla Ruiz y Roger Calderón Urbina (pasantes de la Universidad de Costa Rica, agosto-noviembre 2025), incorporando los módulos y cambios de enfoque desarrollados en la continuación del proyecto como ServIA.

Dicho documento está dirigido a: el tutor y stakeholder principal Carlos Morales Castro, el estudiante practicante, y cualquier persona desarrolladora futura que deba auditar, extender o mantener el sistema.

Este documento es, además, una herramienta de planificación: los requisitos describen el comportamiento que el sistema debe tener, tomando como punto de partida lo ya construido. Cuando el sistema actual difiere de un requisito, es el sistema el que se ajusta al requisito, y el estado de cada requisito indica qué falta (ver sección 3).

1.2 Ámbito del Sistema

Nombre del sistema: "ServIA" — Asistente de inteligencia artificial gubernamental de propósito general, conducido por la Dirección de Gobernanza del MICITT.

ServIA es una plataforma de ingesta, análisis y consulta conversacional de documentos institucionales mediante inteligencia artificial generativa (RAG). El sistema organiza toda su información bajo la filosofía de "tema": una colección de documentos que un usuario crea y nombra, sin vocabulario ni formato judicial. El sistema permite cargar documentos de texto, audio e imagen, procesarlos, vectorizarlos, y conversar con ellos mediante un asistente que responde citando siempre la fuente. El caso de uso con el que el sistema fue validado inicialmente es la consulta de expedientes judiciales del Poder Judicial de Costa Rica (origen histórico del proyecto, como JusticIA) — el concepto de "expediente" pertenece a ese proyecto original y no es el eje de diseño de ServIA.

El sistema abarca todo el flujo operativo: autenticación y gestión de usuarios; ingesta, extracción, reconocimiento y vectorización de la información; consulta conversacional y presentación de resultados; búsqueda de contenido similar; y bitácora de auditoría.

El sistema NO sustituye los sistemas de gestión documental de cada institución, no emite resoluciones ni documentos oficiales, no sustituye el criterio profesional de los funcionarios, y no ofrece reconocimiento confiable de manuscrito a nivel de producción, ya sea cursivo o de imprenta (ver 2.4, Restricciones).

1.3 Definiciones, Acrónimos y Abreviaturas

- ERS: Especificación de Requisitos de Software basada en el estándar IEEE 830-1998.
- RF: Requisito Funcional — describe una función o servicio que el sistema debe proporcionar.
- RNF: Requisito No Funcional — condición o restricción del sistema (rendimiento, seguridad, usabilidad).
- RAG (Retrieval-Augmented Generation): técnica que combina búsqueda de información relevante con generación de texto por un modelo de lenguaje.
- HTR (Handwritten Text Recognition): reconocimiento de texto manuscrito a partir de imágenes.
- OCR (Optical Character Recognition): reconocimiento óptico de caracteres, para texto impreso o tipeado (generado por máquina) en imágenes.
- LLM (Large Language Model): modelo de lenguaje de gran tamaño usado para generar respuestas en lenguaje natural.
- Tema: unidad genérica con la que ServIA organiza y agrupa documentos — no atada a un caso judicial ni a ningún formato institucional específico. Es el eje de diseño del sistema de ahora en adelante.
- Expediente: identificador único de un caso judicial; concepto propio del proyecto original Justicia, con el que el sistema fue validado inicialmente, y que hoy sigue siendo el formato técnico usado internamente para representar un tema del Poder Judicial.
- Notebook (NotebookServIA): colección de documentos genérica que un usuario crea y nombra, con chat propio — implementación concreta del concepto de "tema".
- Embeddings: representación numérica vectorial de un texto, usada para búsqueda semántica.
- Chunk: fragmento en el que se divide un documento antes de vectorizarlo.
- Usuario Gubernamental: funcionario público de cualquier institución del Sector Público que usa el sistema; único tipo de usuario final.
- MICITT: Ministerio de Ciencia, Innovación, Tecnología y Telecomunicaciones de Costa Rica.
- JWT (JSON Web Token): mecanismo de autenticación basado en tokens firmados, usado para proteger la API.
- API REST: interfaz de programación que expone las funciones del backend mediante peticiones HTTP.

- Docker: tecnología de contenedores usada para empaquetar y ejecutar cada servicio del sistema de forma aislada y reproducible.
- Ollama: motor de inferencia local de modelos de lenguaje, usado para correr el LLM sin depender de servicios en la nube.
- Qdrant: motor de base de datos vectorial usado para la búsqueda semántica.
- Celery: sistema de procesamiento asíncrono de tareas en segundo plano (ingesta de documentos).
- Bitácora: registro de auditoría de las acciones relevantes del sistema.

1.4 Referencias

- Documento de Visión – ServIA
- StakeHolder – ServIA
- Historias de Usuario - ServIA
- Documentación técnica interna del proyecto ServIA.
- Repositorio del proyecto: github.com/procmc/Justicia

1.5 Visión General del Documento

Este documento se organiza en cuatro secciones. La sección 1 (Introducción) presenta el propósito del documento, el ámbito del sistema y la terminología utilizada. La sección 2 (Descripción General) expone la perspectiva del producto, sus funciones a alto nivel, el perfil de usuarios, las restricciones y los supuestos y dependencias del proyecto. La sección 3 (Requisitos Específicos) detalla, módulo por módulo, los requisitos funcionales y no funcionales del sistema con su descripción, salida esperada, prioridad, estado de implementación y, en el caso de los requisitos funcionales, su trazabilidad hacia las historias de usuario y los casos de uso. La sección 4 (Apéndices) incluye la matriz de trazabilidad completa y referencias complementarias.

2. Descripción General

2.1 Perspectiva del Producto

ServIA es la continuidad de Justicia. Es un sistema construido como monolito modular — no como arquitectura de microservicios, a diferencia de lo previsto en el análisis de requerimientos original — con backend en FastAPI (Python) y frontend en Next.js (React), orquestado con Docker Compose sobre ocho servicios: backend, celery-worker (procesamiento asíncrono), tika (extracción de texto), redis (cola de tareas), sqlserver (base de datos relacional, local), ollama (modelo de lenguaje local), qdrant (base de datos vectorial) y el servidor de reconocimiento de escritura (HTR).

El sistema funciona en infraestructura 100% local, sin dependencias de servicios de inteligencia artificial en la nube, por la sensibilidad de la información judicial y gubernamental que procesa. Esta es una decisión

de diseño distinta de la prevista originalmente (que contemplaba Azure SQL Server y un LLM potencialmente externo); toda la plataforma corre autoalojada.

2.2 Funciones del Producto

Las funciones del sistema se agrupan por módulo funcional. Todas están disponibles para el rol Usuario Gubernamental, salvo las de administración, exclusivas del rol Administrador.

2.2.1 Seguridad y Acceso

ID	Función	Descripción
FS-01	Autenticación	Inicio y cierre de sesión con usuario y contraseña, validados contra la base de datos interna con cifrado; la sesión expira tras una hora de inactividad.
FS-02	Gestión de roles	Dos roles: Administrador (gestión de usuarios y bitácora) y Usuario Gubernamental (ingesta, consulta y búsqueda).
FS-03	Recuperación de contraseña	Reseteo por administrador o autoservicio por código; el envío de la notificación por correo depende de una cuenta configurada (ver 2.4), y todo fallo de envío se informa.
FS-04	Perfil de usuario	Cada usuario puede configurar un avatar o fotografía de perfil visible en la interfaz, y cambiar su contraseña de forma voluntaria.
FS-05	Gestión de usuarios	El Administrador crea, edita, desactiva y restablece la contraseña de las cuentas de usuario.

2.2.2 Ingesta de Datos

ID	Función	Descripción
FI-01	Carga de archivos multiformato	Carga de documentos de texto, audio e imagen (lista completa en RT-01), desde Ingesta de Datos o desde NotebookServIA, validando formato y tamaño.
FI-02	Asociación a un tema	Cada archivo se vincula obligatoriamente a un tema: el que el usuario indica al cargarlo, o el notebook en el que lo carga.
FI-03	Procesamiento automatizado	Extracción de texto con Apache Tika; transcripción de audio; reconocimiento de imágenes vía HTR.
FI-04	Vectorización y almacenamiento	El texto extraído se convierte en embeddings y se indexa en Qdrant para búsqueda semántica.

2.2.3 Reconocimiento de Escritura (HTR)

ID	Función	Descripción
FH-01	Reconocimiento de texto en imagen	Pipeline de detección y reconocimiento (docTR + TrOCR) orientado exclusivamente a texto impreso o tipeado, es decir, generado por una máquina (documento escaneado, captura de pantalla).
FH-02	Limitación de manuscrito, cursivo y de imprenta	El reconocimiento confiable de manuscrito queda fuera de alcance — tanto en letra cursiva como en letra de imprenta (escritura a mano en trazos separados), porque ambas siguen siendo escritas por una persona y varían de una instancia a otra. Documentado como limitación aceptada (ver 2.4).

2.2.4 Asistente de Consulta (Chat con IA)

ID	Función	Descripción
FA-01	Interfaz de chat	Ventana de conversación en lenguaje natural, con historial visible durante la sesión.
FA-02	Alcance de consulta	General (todo el sistema), acotada a un tema específico, o limitada a los documentos de un notebook de NotebookServIA.
FA-03	Respuestas con cita de fuente	Toda respuesta cita el documento del que proviene la información, con reglas anti-alucinación.
FA-04	Resúmenes y borradores	Generación de resúmenes de documentos o temas, y borradores de texto a partir del contenido consultado.
FA-05	Persistencia del historial	El historial de conversación se conserva al volver a un tema, sin perderse al recargar la página; las conversaciones guardadas pueden retomarse o eliminarse.
FA-06	Copiar y reintentar	Acciones rápidas para copiar la respuesta del asistente o reintentar la misma pregunta, en el Asistente Virtual y en los notebooks.

2.2.5 Búsqueda Híbrida

ID	Función	Descripción
FB-01	Filtro exacto por tema	Si la pregunta menciona de forma exacta el identificador de un tema, el sistema combina el filtro exacto con la búsqueda semántica en vez de depender solo de similitud.
FB-02	Red de seguridad	Si el tema detectado no tiene datos, el sistema reintenta la búsqueda sin el filtro en vez de devolver una respuesta vacía.

2.2.6 NotebookServIA

ID	Función	Descripción
FN-01	Creación de notebooks	Cualquier Usuario Gubernamental puede crear y nombrar un tema propio (notebook).
FN-02	Carga y previsualización	Subida de documentos al notebook, con previsualización del archivo original (imagen o PDF) sin forzar descarga.
FN-03	Chat acotado al notebook	Conversación con IA limitada a los documentos de ese notebook.
FN-04	Eliminación de documentos	Un documento puede quitarse del notebook, previa confirmación (chunks vectoriales, archivo físico y registro en base de datos).

2.2.7 Búsqueda de Temas Similares

ID	Función	Descripción
FT-01	Entrada de criterio de búsqueda	El usuario proporciona un tema de referencia o un fragmento de texto.
FT-02	Listado de resultados ordenado	El sistema presenta los temas o documentos más similares, ordenados por grado de coincidencia y clasificados en similitud alta, media o baja.
FT-03	Resumen con IA	Sobre cada resultado, el modelo de lenguaje local genera un resumen, palabras clave, factores de similitud y una conclusión.

2.2.8 Bitácora y Reportes

ID	Función	Descripción
FR-01	Registro automático de acciones	Todo acceso, operación sobre usuarios, carga de documento, consulta o búsqueda relevante se registra sin intervención manual.
FR-02	Consulta con filtros	Los administradores pueden filtrar la bitácora por usuario, fecha, tipo de acción y tema asociado, ver el detalle de cada registro y exportarla a PDF.
FR-03	Dashboard de métricas	Tarjetas de estadísticas, distribución por tipo de acción, actividad diaria reciente, usuarios más activos y temas más consultados.

2.3 Características de los Usuarios

El sistema reconoce dos tipos de actores. El Poder Judicial es hoy el segmento con el que el sistema fue validado inicialmente, pero ambos roles están pensados para cualquier institución del Sector Público.

2.3.1 Usuario Gubernamental

Atributo	Descripción
Nivel de acceso	Funciones de ingesta, consulta, búsqueda de temas similares y uso de NotebookServIA.
Nivel tecnológico esperado	Básico a intermedio; la interfaz debe ser clara y directa.
Dispositivos de uso	Computadoras de escritorio institucionales, dentro de la red de la institución correspondiente.
Idioma	Español. El sistema debe estar completamente en español.
Tipo de necesidad	Consultar y analizar documentos institucionales de forma rápida y verificable, sin exponer información sensible a la nube.

2.3.2 Administrador

Atributo	Descripción
Nivel de acceso	Gestión de usuarios (creación, edición, desactivación lógica) y acceso completo a la bitácora.
Responsabilidades relevantes	Mantener el sistema seguro, revisar la trazabilidad de uso, y atender los avisos del sistema cuando una notificación por correo no pueda entregarse (ver RF-03).

2.4 Restricciones

2.4.1 Restricciones del Negocio

ID	Restricción	Descripción
RN-01	Conservación de la información	No se permite la eliminación física de registros; la gestión se realiza mediante cambios de estado. La única excepción son los documentos que un usuario carga en sus propios notebooks, que puede quitar de forma definitiva (RF-19).
RN-02	Inmutabilidad de archivos	No se puede reemplazar un archivo ya cargado; cualquier cambio requiere cargar un nuevo registro.
RN-03	Permisos de ingesta y consulta	Solo el rol Usuario Gubernamental accede a ingesta, consulta y búsqueda; el Administrador no realiza estas funciones.

2.4.2 Restricciones Técnicas

ID	Restricción	Descripción
RT-01	Formatos de archivo admitidos	Texto: PDF, DOC, DOCX, RTF, TXT, HTML, HTM, XHTML. Audio: MP3, WAV, OGG, M4A. Imagen: JPG, JPEG, PNG, TIF, TIFF, BMP.
RT-02	Infraestructura 100% local	El sistema debe ejecutarse sin servicios de inteligencia artificial en la nube, por la sensibilidad de la información que procesa.
RT-03	GPU compartida	El modelo de lenguaje y el reconocimiento de escritura comparten una GPU con 8 GB de VRAM, un límite estrecho que no permite experimentar libremente con modelos más grandes.
RT-04	Origen de los modelos de IA	Se excluyen modelos de inteligencia artificial de origen chino por restricción institucional, lo que descartó varias opciones viables para reconocimiento de manuscrito.
RT-05	Reconocimiento de manuscrito cursivo y en imprenta	Queda fuera de alcance con un nivel de confiabilidad de producción: ningún modelo evaluado reconoce de forma confiable escritura a mano —ni cursiva ni de imprenta— dentro de las restricciones de idioma, procesamiento local, GPU y origen. Limitación aceptada del sistema; el enfoque sustituto es el reconocimiento de texto impreso o tipeado generado por máquina (RT-01/FH-01), no de ningún tipo de escritura a mano.
RT-06	Vocabulario del modelo de datos	El modelo de datos conserva el concepto de "expediente", propio del proyecto original Justicia, en varias partes del sistema fuera de NotebookServIA. Su generalización completa hacia el concepto de "tema" ya está autorizada y es un objetivo activo del proyecto. Los requisitos de este documento ya se expresan en términos de tema; donde el sistema todavía conserva el formato heredado, el estado del requisito correspondiente lo indica.
RT-07	Idioma del sistema	La interfaz y las respuestas del asistente deben estar completamente en español.

2.4.3 Restricciones de Alcance

ID	Restricción	Descripción
RA-01	Equipo de desarrollo reducido	El sistema se desarrolla por un único estudiante practicante dentro del período académico de la Práctica Profesional Supervisada.

ID	Restricción	Descripción
RA-02	Cobertura progresiva de pruebas automatizadas	Ningún requisito se da por cumplido solo con verificación manual: cada uno debe cubrirse con pruebas automatizadas (unitarias, de integración y de extremo a extremo), además de la verificación manual de punta a punta. Por el tamaño del equipo (RA-01) y el período de la práctica, el código heredado de Justicia, que no tiene pruebas automatizadas, se cubre de forma progresiva, priorizando los flujos críticos y los módulos de mayor riesgo, con la meta de al menos una prueba automatizada por requisito y no la cobertura total del código. Estado actual: la suite de pruebas automatizadas todavía no existe; mientras se incorpora, la verificación funcional se realiza de forma manual.

2.5 Suposiciones y Dependencias

Estas condiciones se asumen verdaderas para que el sistema funcione correctamente. Si alguna falla, el proyecto se ve afectado.

- S-01. Se asume que el tutor (Carlos Morales Castro) participará activamente en la validación de decisiones técnicas e institucionales.
- S-02. Se asume que la Dirección de Gobernanza del MICITT continuará definiendo y ampliando el alcance de uso gubernamental del sistema conforme avance el proyecto.
- S-03. Se asume que el corpus de documentos de prueba seguirá proviniendo de fuentes oficiales autorizadas por la institución.
- S-04. Se asume acceso continuo a la infraestructura de cómputo local necesaria para ejecutar el modelo de lenguaje y el reconocimiento de escritura.

Dependencias técnicas internas

El asistente de consulta depende de que el motor de lenguaje local (Ollama) y la base de datos vectorial (Qdrant) estén disponibles; una caída de cualquiera de los dos servicios detiene el chat. La ingesta depende del servicio de extracción de texto (Tika) y del worker asíncrono (Celery); si el worker no puede conectarse a la base de datos al arrancar, ningún archivo se procesa hasta reiniciarlo.

Dependencias de fuentes de datos

Ampliación del corpus con documentos de interés general para el país. Se propuso como fuente Nexus.PJ (jurisprudencia, actas, circulares y avisos del Poder Judicial) y se envió la solicitud al tutor el 25 de setiembre de 2026; la respuesta está pendiente. Una vez resuelta, queda como tarea del practicante definir el alcance concreto y ejecutar la carga. Hasta entonces, el corpus del sistema sigue siendo predominantemente judicial.

Se solicitó a una institución universitaria el corpus de manuscrito SPA-Sentences, con respuesta pendiente. No constituye una dependencia del alcance actual: el reconocimiento de escritura a mano ya

está fijado como limitación aceptada (RF-10), y si el corpus llegara a obtenerse, su uso sería un valor agregado adicional, sin cambiar el enfoque del proyecto.

Dependencias organizacionales

Cuenta de correo institucional o de desarrollo para las notificaciones del sistema (reseteo de contraseña, recuperación por código); mientras no se configure, esas notificaciones no llegan a los usuarios reales.

3. Requisitos Específicos

A continuación se detallan los requisitos funcionales y no funcionales del sistema. Cada uno indica su descripción, la salida o criterio esperado, su prioridad y su estado de implementación, con el nivel de detalle necesario para evitar ambigüedad en su interpretación. Cada requisito funcional indica además su trazabilidad hacia las historias de usuario (HU) y los casos de uso (CU) que lo desarrollan.

El estado compara el requisito con el sistema actual: Implementado (el sistema ya lo cumple), Parcial (lo cumple en parte; la descripción señala qué falta en un párrafo que inicia con "Estado actual") o Limitación aceptada (queda fuera de alcance por las restricciones del proyecto).

3.1 Requisitos Funcionales

Módulo 1: Seguridad y Acceso

RF-01 — Autenticación y cierre de sesión

Descripción: El sistema debe permitir que el Usuario Gubernamental y el Administrador inicien sesión desde la pantalla "Inicio de sesión" con su usuario (correo electrónico) y su contraseña. Para autenticar, el sistema busca la cuenta por el correo ingresado, compara la contraseña contra el hash almacenado (algoritmo de hash con sal; la contraseña nunca se guarda ni se compara en texto plano) y verifica que la cuenta esté en estado Activo. Si la autenticación es exitosa, genera un token JWT firmado que contiene el identificador, el rol y el correo del usuario, con un tiempo de expiración definido; ese token acompaña cada solicitud posterior a la API y es la base de la verificación de permisos (RF-02).

Reglas y validaciones: Ambos campos son obligatorios y el correo debe tener un formato válido antes de enviar la solicitud; la contraseña puede mostrarse u ocultarse mientras se escribe. Si la cuenta es nueva o su contraseña fue restablecida por un administrador, el sistema exige cambiar la contraseña temporal en un panel que no puede cerrarse, y no permite ninguna otra acción hasta completar el cambio; la fecha de último acceso solo se actualiza cuando la sesión queda habilitada sin ese requisito pendiente. Mientras el usuario interactúa con el sistema, la sesión se renueva automáticamente; si transcurre una hora sin actividad, la sesión expira. El usuario puede cerrar la sesión en cualquier momento desde su menú de usuario, y quien intenta abrir una página protegida sin una sesión activa es dirigido a "Inicio de sesión".

Manejo de errores: Si el correo no existe, la contraseña no coincide o la cuenta está en estado Inactivo, el sistema responde siempre con el mismo mensaje genérico ("Credenciales inválidas"), sin

indicar cuál fue la causa, para no facilitar ataques de enumeración de usuarios. Si el servidor no responde, el sistema muestra un mensaje general que invita a intentarlo de nuevo, sin crear ninguna sesión.

Registro: Todo inicio de sesión exitoso, todo intento fallido (con su motivo) y todo cierre de sesión se registran en la bitácora (RF-21). Si el registro del cierre de sesión falla, la sesión se cierra de todas formas.

Salida: En caso de éxito: Sesión activa con un token JWT válido; los datos del usuario autenticado (nombre, correo, rol y avatar) quedan disponibles en la interfaz, el usuario es dirigido a la página de inicio con el menú de su rol y su fecha de último acceso se actualiza. Si corresponde, el panel de cambio de contraseña obligatorio permanece abierto hasta completarse.

En caso de error: Mensaje "Credenciales inválidas" sin detalle de la causa y sin sesión creada; el intento fallido queda registrado en la bitácora.

Al cerrar la sesión: La sesión deja de ser válida, las páginas protegidas dejan de estar accesibles y el sistema muestra "Inicio de sesión", ya sea por decisión del usuario o por inactividad.

Prioridad: Alta **Estado:** **Implementado**

Trazabilidad: Historias de usuario HU-01, HU-24 · Casos de uso CU-01, CU-02

RF-02 — Gestión de roles y usuarios

Descripción: El sistema reconoce exactamente dos roles, sin niveles intermedios: Administrador, con acceso a la gestión de usuarios y a la bitácora completa del sistema, incluido el dashboard de métricas; y Usuario Gubernamental, con acceso a la ingesta de documentos, la consulta conversacional, la búsqueda de temas similares y NotebookServIA. Ningún rol accede a las funciones del otro. Cada endpoint protegido del backend debe verificar el rol contenido en el token JWT antes de ejecutar la acción solicitada, y debe rechazar la solicitud con un código de error de autorización si el rol no corresponde, incluso si el usuario está correctamente autenticado.

Control en la interfaz: El menú lateral muestra únicamente las opciones del rol: para el Administrador, "Inicio" y "Administración" ("Usuarios del Sistema" e "Historial de Actividades"); para el Usuario Gubernamental, "Inicio", "Búsqueda y Consulta" ("Asistente Virtual" y "Temas Similares"), "Ingesta de Datos" y "NotebookServIA". Si un usuario escribe directamente la dirección de una página que no corresponde a su rol, el sistema no la muestra y lo dirige a la página de inicio; si no tiene una sesión activa, lo dirige a "Inicio de sesión" y, tras autenticarse, lo devuelve a la página que había solicitado.

Gestión de cuentas: El Administrador gestiona las cuentas desde "Usuarios del Sistema", donde puede buscarlas por nombre, usuario, correo o cargo. Al crear una cuenta indica cédula (solo números, de 8 a 15 dígitos), nombre, primer y segundo apellido, correo electrónico y rol, todos obligatorios; el sistema genera una contraseña temporal aleatoria de 8 caracteres, la almacena cifrada y la envía al correo del usuario, que deberá cambiarla en su primer inicio de sesión (RF-01). El Administrador también puede editar los datos, el rol y el estado de una cuenta, restablecer su contraseña (RF-03) y desactivarla de forma lógica, pasando su estado a Inactivo sin eliminarla; una cuenta Inactiva no puede iniciar sesión. Cada operación sobre una cuenta se registra en la bitácora (RF-21).

Manejo de errores: Si un dato de la cuenta falta o es inválido, el sistema señala el campo con un mensaje específico (por ejemplo, que la cédula debe contener solo números de 8 a 15 dígitos o que el formato del correo no es válido) y no guarda la cuenta. Si el correo con la contraseña temporal no puede enviarse, la cuenta se crea igualmente y el sistema debe informar al Administrador que la notificación no fue entregada.

Estado actual: cuando el correo con la contraseña temporal de una cuenta nueva no puede enviarse, el sistema todavía no se lo informa al Administrador (ver RF-03).

Salida: En caso de éxito: Acceso concedido únicamente a las funciones habilitadas para el rol del usuario; cuentas creadas, editadas o desactivadas según lo indique el Administrador, con un mensaje de confirmación ("Usuario creado exitosamente" o "Usuario actualizado exitosamente") y cada operación registrada en la bitácora.

En caso de error: Rechazo explícito con un error de autorización —no un error genérico del servidor— ante cualquier intento de acceder a una función fuera del rol; mensaje específico por campo cuando los datos de una cuenta son inválidos, sin guardar cambios.

Prioridad: Alta **Estado:** Parcial

Trazabilidad: Historias de usuario HU-02, HU-25 · Casos de uso CU-03, CU-05

RF-03 — Recuperación de contraseña

Descripción: El sistema ofrece dos vías para recuperar el acceso a una cuenta: (a) un administrador puede resetear la contraseña de cualquier usuario desde el módulo de gestión de usuarios, generando una contraseña aleatoria de 8 caracteres que se envía al correo del usuario; y (b) el propio usuario puede recuperarla desde el enlace "¿Olvidaste tu contraseña?" de la pantalla de inicio de sesión, en tres pasos: indica su correo registrado, ingresa el código de recuperación de 6 dígitos que recibe (válido por 15 minutos) y define su nueva contraseña.

Reglas y validaciones: En la vía (b), el sistema responde siempre con el mismo mensaje ("Si el correo existe en nuestro sistema, recibirás un email con las instrucciones"), sin revelar si la cuenta existe. Una vez verificado el código, el usuario dispone de 10 minutos para definir la nueva contraseña, que debe tener al menos 8 caracteres, ser distinta de la actual y confirmarse escribiéndola dos veces, con un indicador de su fortaleza. Solo en la vía (a) el campo de último acceso del usuario se limpia para forzar el cambio de la contraseña temporal en el siguiente inicio de sesión (RF-01); en la vía (b) no es necesario, porque la nueva contraseña la define el propio usuario. Cada paso —solicitud, verificación exitosa o fallida del código y restablecimiento por administrador— se registra en la bitácora (RF-21).

Manejo de errores: Si el código es incorrecto o expiró, el sistema lo indica y permite solicitar uno nuevo; si vencieron los 10 minutos para definir la contraseña, pide iniciar el proceso de nuevo; si la nueva contraseña es igual a la actual, lo indica y no la guarda. Si el correo no puede enviarse, el sistema debe informarlo: al usuario, en la vía (b), y al administrador, en la vía (a).

Estado actual: no existe una cuenta de correo real configurada en el entorno (ver RT en 2.4), por lo que el envío del correo falla en silencio — la contraseña sí se actualiza en la base de datos, pero la notificación nunca llega al usuario, y el administrador que ejecutó el reseteo no recibe ninguna alerta

de que el envío falló. Se acordó con el tutor que el practicante trabaje con una cuenta de correo de desarrollo propia mientras se resuelve el aspecto institucional definitivo, que queda a cargo de Carlos Morales Castro (Director de Gobernanza, MICITT) más adelante. Mientras tanto, el desbloqueo de una cuenta real sigue requiriendo intervención manual directa sobre la base de datos.

Salida: *En caso de éxito:* Contraseña actualizada y cifrada en la base de datos. En la vía (b), el sistema muestra "Contraseña recuperada exitosamente" y el usuario regresa a "Inicio de sesión"; en la vía (a), el administrador recibe la confirmación del restablecimiento y el usuario recibe por correo su contraseña temporal, cuando exista una cuenta de correo configurada.

En caso de error: Mensaje específico según la causa —código incorrecto o expirado, tiempo vencido, contraseña repetida o fallo del envío del correo—, sin modificar la contraseña cuando el proceso no se completa.

Prioridad: Alta **Estado:** Parcial

Trazabilidad: Historias de usuario HU-03, HU-25 · Casos de uso CU-04, CU-05

RF-04 — Perfil de usuario (avatar y contraseña)

Descripción: Cada usuario puede personalizar la imagen con la que se le identifica en el sistema desde la opción "Cambiar avatar" de su menú de usuario, eligiendo un avatar predefinido o cargando una fotografía propia, y puede restablecer en cualquier momento el avatar generado con sus iniciales. El avatar seleccionado se muestra de forma consistente junto al nombre del usuario en toda la interfaz —incluida el área de chat, donde identifica los mensajes enviados por ese usuario— sin necesidad de recargar la página tras el cambio. Desde el mismo menú, la opción "Cambiar contraseña" le permite cambiar su contraseña de forma voluntaria.

Reglas y validaciones: La fotografía debe ser JPG, PNG, GIF o WebP y pesar como máximo 5 MB. Antes de guardarla, el sistema muestra una vista previa temporal, y el cambio solo se aplica al pulsar "Guardar Avatar"; "Cancelar" conserva el avatar anterior. Para cambiar la contraseña, el usuario indica la contraseña actual, la nueva y su confirmación; la nueva debe tener al menos 8 caracteres y ser distinta de la actual. El cambio de contraseña se registra en la bitácora (RF-21).

Manejo de errores: Si la imagen no tiene un formato permitido o supera el tamaño máximo, el sistema lo indica ("Formato no válido. Use JPG, PNG, GIF o WebP" o "La imagen es muy grande. Tamaño máximo: 5MB") y no la acepta; si el almacenamiento falla, conserva el avatar anterior e informa el error. Si la contraseña actual es incorrecta o la nueva no cumple las reglas, el sistema lo indica y no modifica la contraseña.

Salida: *En caso de éxito:* Avatar actualizado y visible de inmediato en todos los puntos de la interfaz donde aparece el usuario, con el mensaje "Avatar actualizado correctamente" (o "Avatar restablecido correctamente" al volver a las iniciales); contraseña actualizada y cifrada cuando el usuario la cambia.

En caso de error: Mensaje específico del problema, sin cambios en el avatar ni en la contraseña.

Prioridad: Baja **Estado:** Implementado

Trazabilidad: Historias de usuario HU-04 · Casos de uso CU-06

Módulo 2: Ingesta de Datos

RF-05 — Carga de archivos multiformato

Descripción: El sistema debe permitir cargar archivos de texto (PDF, DOC, DOCX, RTF, TXT, HTML, HTM, XHTML), audio (MP3, WAV, OGG, M4A) e imagen (JPG, JPEG, PNG, TIF, TIFF, BMP), tanto desde la pantalla de Ingesta de Datos como desde un notebook de NotebookServIA. Las imágenes admitidas son las que contienen texto impreso o tipeado —por ejemplo, capturas de pantalla o documentos impresos escaneados o fotografiados—, y la pantalla de carga advierte que la escritura a mano no se reconoce de forma confiable (RF-10).

Flujo de carga: El usuario selecciona uno o varios archivos o los arrastra a la zona de carga; el sistema los muestra en una lista con el tamaño de cada uno y el tamaño total, y permite quitar cualquiera antes de confirmar. En Ingesta de Datos, el usuario indica además el tema (RF-06) y confirma en una ventana que resume la carga y advierte que los archivos quedarán asociados de forma permanente a ese tema. En un notebook, la carga se confirma con "Confirmar y subir", y pegar (Ctrl+V) o arrastrar una imagen sobre el chat la carga de inmediato, sin la lista de revisión.

Reglas y validaciones: El sistema valida tanto la extensión como el tipo MIME real de cada archivo (no solo su nombre) y un tamaño máximo de 1GB por archivo, de forma consistente en el frontend (para evitar una carga innecesaria) y en el backend (como validación definitiva). No existe un límite para la cantidad de archivos de una misma carga: cada archivo se valida y se procesa de forma independiente.

Manejo de errores: Un archivo con un formato no permitido o que supera el tamaño máximo se rechaza con un mensaje que indica el motivo específico y los formatos permitidos, sin impedir la carga de los demás archivos válidos. Si se pierde la comunicación con el servidor, el sistema lo informa y permite intentarlo de nuevo.

Estado actual: la pantalla de Ingesta de Datos todavía no admite imágenes, que hoy solo pueden cargarse desde NotebookServIA, y la advertencia sobre la escritura a mano aún no se muestra.

Salida: En caso de éxito: Cada archivo aceptado queda almacenado y encolado para su procesamiento asíncrono con un identificador de tarea, y el sistema confirma que la carga se inició y que los archivos se procesan en segundo plano (RF-07).

En caso de error: Mensaje específico por cada archivo rechazado, que indica si el problema fue el formato, el tamaño o la conexión, sin afectar a los archivos aceptados.

Prioridad: Alta **Estado:** Parcial

Trazabilidad: Historias de usuario HU-05 · Casos de uso CU-07

RF-06 — Asociación a un tema

Descripción: Todo archivo cargado debe vincularse obligatoriamente a un tema antes de ser aceptado por el sistema. En la pantalla de Ingesta de Datos, el usuario indica el tema por su nombre; si la carga se hace desde NotebookServIA, el tema es el propio notebook y no es necesario indicarlo. Un archivo nunca queda

huérfano: si el tema indicado no existe, el sistema lo crea automáticamente al momento de la carga, y si ya existe, el archivo se agrega a los documentos de ese tema.

Reglas y validaciones: El nombre del tema es obligatorio: mientras no se indique, el sistema no permite confirmar la carga. La asociación entre un archivo y su tema es permanente; un archivo no puede moverse a otro tema, y cualquier cambio requiere cargarlo de nuevo (RN-02). El tema de cada archivo se guarda también en los metadatos de sus fragmentos vectoriales (RF-08), para que las consultas y búsquedas puedan acotarse a ese tema (RF-11, RF-13).

Estado actual: la pantalla de Ingesta de Datos todavía exige un identificador con el formato heredado del proyecto JusticiaA, en lugar de un nombre de tema libre (ver RT-06).

Salida: En caso de éxito: Archivo asociado a su tema en la base de datos relacional y en los metadatos de la base vectorial, recuperable en consultas posteriores acotadas a ese tema.

En caso de error: Si no se indicó el tema, la carga no se confirma y el sistema solicita indicarlo.

Prioridad: Alta **Estado:** Parcial

Trazabilidad: Historias de usuario HU-06 · Casos de uso CU-07

RF-07 — Procesamiento automatizado del contenido

Descripción: El sistema procesa cada archivo aceptado de forma asíncrona, en segundo plano mediante Celery, sin bloquear la interfaz del usuario. Según su tipo, los documentos de texto se procesan con Apache Tika para extraer su contenido; el audio se transcribe automáticamente (Whisper); y las imágenes se procesan mediante el pipeline de reconocimiento de escritura (Módulo 3). El texto obtenido pasa a la vectorización (RF-08).

Seguimiento: El estado de cada documento transita entre exactamente tres valores — Pendiente, Procesado o Error — y el progreso del procesamiento, en porcentaje, es visible para el usuario en tiempo real mediante consultas de seguimiento periódicas, junto con los contadores de archivos pendientes, completados y con error. El usuario puede cancelar el procesamiento de un archivo mientras está en curso; el archivo queda marcado como cancelado por el usuario.

Manejo de errores: Si el procesamiento de un archivo falla, el documento queda en estado Error con un mensaje descriptivo de la causa, sin bloquear el procesamiento de los demás archivos en curso. Si un mismo archivo llega a procesarse dos veces por un reintento interno del sistema, este lo detecta y no lo duplica.

Salida: En caso de éxito: Texto extraído del archivo, listo para vectorizar (RF-08), y estado del documento actualizado a Procesado, visible para el usuario.

En caso de error: Documento en estado Error con el detalle de la causa, o marcado como cancelado cuando el usuario detuvo el procesamiento.

Prioridad: Alta **Estado:** Implementado

Trazabilidad: Historias de usuario HU-07 · Casos de uso CU-07

RF-08 — Vectorización y almacenamiento semántico

Descripción: El texto extraído de cada documento se divide en fragmentos (chunks) de tamaño acotado, preservando el contexto necesario para que cada fragmento sea comprensible de forma independiente. Cada chunk se convierte en un vector numérico (embedding) mediante un modelo de lenguaje multilingüe, y se almacena e indexa en la base de datos vectorial Qdrant junto con sus metadatos (tema de origen, nombre de archivo, tipo de documento, número de página o fragmento), necesarios para que las respuestas del asistente puedan citar la fuente exacta.

Reglas y validaciones: Todos los fragmentos se generan con el mismo modelo de embeddings, para que las búsquedas comparen vectores equivalentes. El documento pasa a estado Procesado solo cuando la indexación de sus fragmentos termina, y desde ese momento queda disponible para el asistente de consulta (RF-11) y la búsqueda de temas similares (RF-20). Al eliminar un documento de un notebook, sus fragmentos se eliminan de Qdrant junto con el resto de sus datos (RF-19).

Manejo de errores: Si la vectorización o el almacenamiento en Qdrant fallan, el documento queda en estado Error (RF-07) con el detalle de la causa.

Salida: En caso de éxito: Embeddings del documento indexados en Qdrant con sus metadatos completos, disponibles de inmediato para la búsqueda semántica, el asistente de consulta y la búsqueda de temas similares.

En caso de error: Documento en estado Error con el detalle de la causa.

Prioridad: Alta **Estado:** Implementado

Trazabilidad: Historias de usuario HU-08 · Casos de uso CU-07

Módulo 3: Reconocimiento de Escritura (HTR)

RF-09 — Reconocimiento de texto en imagen

Descripción: Cuando se carga un archivo de imagen, el sistema localiza las líneas de texto mediante un modelo de detección (docTR) y reconoce su contenido mediante un modelo de reconocimiento (TrOCR). Este pipeline está orientado exclusivamente a texto impreso o tipeado generado por una máquina —por ejemplo, una captura de pantalla, un documento impreso fotografiado, o un formulario tipeado escaneado—, donde cada carácter mantiene una forma geométrica consistente entre una instancia y otra.

Reglas y validaciones: Se procesan las imágenes JPG, JPEG, PNG, TIF, TIFF y BMP cargadas mediante RF-05, sin importar si provienen de la pantalla de Ingesta de Datos o de un notebook. El reconocimiento se ejecuta en un servicio propio dentro de la infraestructura local (RNF-09). El texto reconocido se trata igual que el de un documento de texto: se vectoriza con los mismos metadatos de tema y archivo (RF-08), de modo que el asistente puede citar la imagen como fuente y el usuario puede verla en su formato original (RF-18).

Manejo de errores: Si el servicio de reconocimiento no está disponible o no puede procesar la imagen, el documento queda en estado Error (RF-07). Si la imagen contiene escritura a mano, el resultado no se considera confiable (RF-10).

Estado actual: la medición del 5 de octubre de 2026 sobre capturas de pantalla (10 imágenes y 155 líneas) mostró que el reconocedor en producción, entrenado con manuscrito en inglés, no cumple el criterio de calidad: su error de caracteres promedio es 0,121 y el criterio exige 0,10 o menos, y pierde las tildes y la ñ. El detector docTR obtuvo 0,048, pero tampoco escribe la mayoría de las tildes ni la ñ; el reconocedor definitivo se decide en la integración y puede cambiar el pipeline descrito aquí (docTR y TrOCR). Las fotos con celular y los escaneos todavía no se han medido.

Salida: En caso de éxito: Texto reconocido de la imagen, integrado al flujo normal de vectorización (RF-08) con la misma trazabilidad de fuente que un documento de texto nativo, y documento en estado Procesado.

En caso de error: Documento en estado Error con el detalle de la causa.

Prioridad: Alta **Estado:** Parcial

Trazabilidad: Historias de usuario HU-09 · Casos de uso CU-08

RF-10 — Limitación de reconocimiento de manuscrito (cursivo y de imprenta)

Descripción: El reconocimiento confiable de escritura manuscrita —tanto en letra cursiva (trazos enlazados) como en letra de imprenta (trazos separados, pero seguimos hablando de escritura hecha a mano)— queda fuera de alcance con un nivel de confiabilidad aceptable para producción. La causa no es cursiva contra imprenta: es que cualquier escritura hecha por una persona, sea cual sea su estilo, varía de una instancia a otra en la forma exacta de cada letra, mientras que el texto generado por máquina (RF-09) no varía. Tras una búsqueda exhaustiva de modelos existentes, ninguno satisface simultáneamente las restricciones del proyecto: reconocimiento real de escritura a mano en español, procesamiento 100% local, la GPU compartida de 8GB de VRAM disponible (RT-03), y la exclusión de modelos de origen chino (RT-04).

Comportamiento esperado: El sistema no puede distinguir de antemano si una imagen contiene escritura a mano, por lo que no la rechaza al cargarla; pero tampoco presenta ese reconocimiento como una funcionalidad confiable: la pantalla de carga advierte que las imágenes deben contener texto impreso o tipeado (RF-05), y el texto que se obtenga de una imagen manuscrita puede contener errores y no debe tomarse como fuente confiable.

Salida: El sistema documenta esta limitación de forma explícita en la interfaz y en la documentación del proyecto, en vez de ofrecer una funcionalidad de reconocimiento de manuscrito no confiable; el único camino soportado es el de RF-09 (texto generado por máquina).

Prioridad: Media **Estado:** Limitación aceptada

Trazabilidad: Historias de usuario HU-10 · Casos de uso CU-08

Módulo 4: Asistente de Consulta (Chat con IA)

RF-11 — Consulta en lenguaje natural

Descripción: El sistema ofrece una interfaz de chat ("Asistente Virtual") donde el Usuario Gubernamental formula preguntas en lenguaje natural sobre los documentos del sistema. El alcance de la búsqueda es

configurable: general (todos los temas a los que el usuario tiene acceso) o acotado a un tema específico, que queda fijado como contexto de toda la conversación; dentro de NotebookServIA, el alcance queda limitado a los documentos del notebook abierto. Para responder, el sistema recupera de la base vectorial los fragmentos más relevantes dentro del alcance definido y los envía como contexto al modelo de lenguaje local, junto con los mensajes anteriores de la conversación, de modo que el usuario puede hacer preguntas de seguimiento.

Reglas y validaciones: La respuesta se genera de forma incremental (streaming), mostrando el texto a medida que el modelo lo produce en vez de esperar la respuesta completa, para reducir la percepción de espera; mientras tanto, el sistema indica la etapa en curso (procesando la consulta, analizando documentos o generando la respuesta). Toda respuesta debe citar sus fuentes (RF-12), la conversación se conserva (RF-14) y cada consulta se registra en la bitácora (RF-21).

Manejo de errores: Si el modelo no devuelve texto, el sistema reintenta automáticamente una vez; si no es posible conectar con el servidor o con el motor de lenguaje, muestra un mensaje de error de conexión con las posibles causas; si la conexión se corta a mitad de la respuesta, se aplica RF-16.

Salida: En caso de éxito: Respuesta generada por el modelo de lenguaje local (Ollama, llama3.1:8b), mostrada en formato conversacional con streaming en tiempo real, con cita de sus fuentes y guardada en la conversación.

En caso de error: Mensaje de error visible en la conversación, con el control de envío disponible para intentarlo de nuevo.

Prioridad: Alta **Estado:** Implementado

Trazabilidad: Historias de usuario HU-11 · Casos de uso CU-09

RF-12 — Respuestas con cita de fuente y sin invención de información

Descripción: Toda respuesta del asistente debe basarse únicamente en los fragmentos de documentos recuperados para esa consulta específica y citar explícitamente el documento de origen de cada afirmación relevante. El prompt del sistema incluye reglas explícitas contra la invención de nombres de archivo, contenido no presente en el contexto recuperado, o atribución de información a un documento incorrecto. Si la pregunta hace referencia ambigua a un documento (por ejemplo, "el archivo que subí" cuando hay varios), el sistema debe pedir una aclaración en vez de asumir a cuál documento se refiere.

Reglas y validaciones: Las fuentes citadas corresponden a los documentos de los fragmentos recuperados para esa consulta; el nombre de cada archivo citado permite descargar el documento original para verificarlo. Dentro de un notebook, las respuestas se basan solo en los documentos de ese notebook. El asistente no completa una respuesta con conocimiento general del modelo cuando el contexto recuperado no la contiene.

Salida: En caso de éxito: Respuesta con cita de fuente visible junto a cada afirmación relevante, con los nombres de archivo citados disponibles para descargar el documento original.

Sin información suficiente: El sistema indica explícitamente que el contexto recuperado no contiene la respuesta, en vez de completarla con conocimiento externo o inventado; ante una referencia ambigua, pide una aclaración.

Prioridad: Alta **Estado:** **Implementado**

Trazabilidad: Historias de usuario HU-12 · Casos de uso CU-09

RF-13 — Búsqueda híbrida por tema

Descripción: Si la pregunta del usuario menciona de forma exacta el identificador de un tema existente, el sistema detecta esa mención y combina un filtro exacto de metadata por ese tema con la búsqueda semántica, en vez de depender solo de similitud sobre toda la base vectorial. Este comportamiento complementa el alcance elegido por el usuario (RF-11): permite acotar una consulta general a un tema sin cambiar el alcance del chat.

Reglas y validaciones: La detección se aplica sobre el texto de la pregunta antes de la búsqueda. Si el tema detectado existe pero no tiene documentos asociados, o el filtro exacto no produce resultados relevantes, el sistema reintenta la búsqueda sin el filtro exacto en vez de devolver una respuesta vacía al usuario, y la respuesta aclara que el tema no tenía datos propios.

Estado actual: la detección reconoce únicamente identificadores con el formato heredado del proyecto Justicia (ver RT-06).

Salida: **En caso de éxito:** Resultados acotados exclusivamente al tema detectado cuando existen datos.

Sin datos del tema: Resultado de búsqueda general, con un aviso claro de que el tema no tenía datos propios.

Prioridad: Alta **Estado:** **Parcial**

Trazabilidad: Historias de usuario HU-13 · Casos de uso CU-09

RF-14 — Persistencia del historial de conversación

Descripción: El sistema conserva los mensajes de una conversación —tanto la pregunta del usuario como la respuesta del asistente— al volver a un tema previamente consultado, o al recargar la página dentro de la misma sesión del navegador, en vez de generar una conversación nueva y vacía cada vez. Cada tema mantiene su propio historial independiente, de forma que cambiar entre varios temas no mezcla ni sobrescribe sus respectivas conversaciones.

Historial de conversaciones: Las conversaciones del Asistente Virtual se guardan en el servidor, asociadas al usuario. Desde la opción "Historial", el usuario ve la lista de sus conversaciones guardadas y puede abrir cualquiera para continuarla con su contexto completo, iniciar una conversación nueva con "Nueva conversación" o eliminar una conversación, acción que requiere una confirmación. En NotebookServIA, cada notebook conserva su propia conversación, que se restaura al volver a abrirlo durante la misma sesión del navegador.

Manejo de errores: Si el historial no puede cargarse, el sistema lo indica y permite reintentar, sin afectar la conversación en curso.

Salida: **En caso de éxito:** Historial completo de mensajes restaurado en la pantalla al volver a un tema o a una conversación, sin pérdida de contexto ni de mensajes previos; listado de conversaciones guardadas disponible para retomarlas o eliminarlas.

En caso de error: Mensaje que indica que el historial no pudo cargarse, con la opción de reintentar.

Prioridad: Media **Estado:** Implementado

Trazabilidad: Historias de usuario HU-14 · Casos de uso CU-09

RF-15 — Copiar y reintentar respuesta

Descripción: El usuario puede copiar el contenido en texto plano de cualquier respuesta del asistente con un solo clic, sin formato adicional que dificulte su reutilización en otro sistema. Adicionalmente, puede reintentar la misma pregunta si la respuesta obtenida no fue satisfactoria, lo que genera una nueva consulta al asistente sin necesidad de volver a escribir el texto de la pregunta original. Ambas acciones deben estar disponibles tanto en el Asistente Virtual como en el chat de cada notebook.

Reglas y validaciones: La acción "Copiar respuesta" aparece sobre cada respuesta del asistente, y "Copiar mensaje" permite copiar también el texto de las preguntas del propio usuario. La acción "Reintentar consulta" aparece sobre la última pregunta del usuario y vuelve a enviarla con el mismo alcance; la nueva respuesta se agrega al final de la conversación, sin borrar la anterior, de modo que el usuario puede compararlas, y sigue las mismas reglas de RF-11 y RF-12.

Estado actual: en el chat de NotebookServIA la acción de reintentar todavía no tiene efecto.

Salida: En caso de éxito: Texto copiado al portapapeles del sistema operativo, o una nueva respuesta para la misma pregunta original agregada al final de la conversación.

En caso de error: Si la nueva consulta falla, se aplica el manejo de errores de RF-11.

Prioridad: Baja **Estado:** Parcial

Trazabilidad: Historias de usuario HU-15 · Casos de uso CU-10

RF-16 — Recuperación ante corte de conexión durante el streaming

Descripción: Si la conexión con el servidor se corta de forma abrupta a mitad de una respuesta en streaming (por ejemplo, por una caída del backend o de la red), el sistema debe detectar la inactividad tras un período de espera definido (30 segundos sin recibir datos) y liberar automáticamente el control de envío de mensajes, marcando la respuesta interrumpida como tal. Antes de esta funcionalidad, el control de envío quedaba bloqueado de forma indefinida hasta que el usuario recargaba la página manualmente, sin ninguna señal de que el sistema seguía disponible.

Reglas y validaciones: El período de espera se cuenta desde el inicio de la consulta y se reinicia con cada fragmento de texto recibido, de modo que la regla también aplica cuando no llega ningún texto. El texto que ya se había recibido antes del corte se conserva en pantalla, seguido del aviso de conexión perdida.

Salida: En caso de corte: Control de envío de mensajes disponible de nuevo tras el período de inactividad, sin intervención manual del usuario; la respuesta conserva el texto recibido y muestra el aviso "Se perdió la conexión con el servidor. Intentá de nuevo."

Prioridad: Media **Estado:** Implementado

Trazabilidad: Historias de usuario HU-16 · Casos de uso CU-09

Módulo 5: NotebookServIA

RF-17 — Creación de notebooks

Descripción: Cualquier Usuario Gubernamental puede crear una colección de documentos propia (notebook), asignarle un nombre libre y descriptivo, y usarla como espacio de trabajo independiente de los demás temas del sistema. Un usuario puede tener múltiples notebooks activos de forma simultánea; cada uno conserva sus propios documentos y su propia conversación, y cambiar de uno a otro no mezcla su contenido.

Reglas y validaciones: El notebook se crea desde el panel "Tus colecciones de documentos" de NotebookServIA, escribiendo su nombre y pulsando el botón de crear o la tecla Enter; el nombre no puede estar vacío. Cada notebook pertenece al usuario que lo creó y recibe un identificador interno propio, con el que se agrupan sus documentos en la base de datos y en la base vectorial. El notebook recién creado aparece al inicio de la lista y se abre de inmediato, con la opción "Subir documentos", la lista de sus documentos —cada uno con un color según su estado: Procesado, Error o Pendiente— y el chat.

Manejo de errores: Si el nombre está vacío, el sistema no crea el notebook; si la creación falla, el notebook no se agrega a la lista.

Salida: En caso de éxito: Notebook creado y abierto de inmediato, disponible en la lista de notebooks del usuario, listo para recibir documentos (RF-05) y para conversar con ellos (RF-11).

En caso de error: El notebook no se crea y la lista no cambia.

Prioridad: Alta **Estado:** Implementado

Trazabilidad: Historias de usuario HU-17 · Casos de uso CU-11

RF-18 — Previsualización de archivos originales

Descripción: El usuario puede hacer clic en un documento ya procesado dentro de un notebook y ver su contenido original (imagen o PDF) directamente en el navegador, renderizado en línea sin forzar una descarga al equipo del usuario, con el fin de verificar visualmente el contenido real del documento contra lo que responde el asistente sobre él.

Reglas y validaciones: Solo pueden abrirse los documentos en estado Procesado; mientras el archivo se obtiene, el documento indica que se está abriendo. Antes de entregar el archivo, el sistema verifica que el documento pertenezca a un notebook del usuario que lo solicita. Las imágenes se muestran directamente y los PDF en un visor integrado, en una ventana que muestra el nombre del archivo. Si el tipo de archivo no admite vista previa (por ejemplo, un audio o un documento de Word), el sistema lo indica en la misma ventana.

Manejo de errores: Si el documento no pertenece a un notebook del usuario, el sistema rechaza la solicitud y no muestra el archivo.

Salida: En caso de éxito: Archivo original mostrado en una ventana de previsualización dentro de la misma interfaz, sin abrir una pestaña ni una descarga separada, y sin modificar el documento.

En caso de error: Aviso de vista previa no disponible para los tipos de archivo sin soporte, o rechazo de la solicitud cuando el documento no pertenece al usuario.

Prioridad: Media **Estado:** Implementado

Trazabilidad: Historias de usuario HU-18 · Casos de uso CU-12

RF-19 — Eliminación de documentos del notebook

Descripción: El usuario puede quitar un documento de un notebook en cualquier momento. Antes de eliminarlo, el sistema solicita una confirmación que indica el nombre del documento y advierte que la acción no puede deshacerse. Al confirmarse, el sistema elimina de forma coordinada sus tres representaciones: los fragmentos vectoriales correspondientes en Qdrant, el archivo físico almacenado en disco, y el registro del documento en la base de datos relacional — evitando que quede información huérfana en cualquiera de las tres capas.

Reglas y validaciones: Antes de eliminar, el sistema verifica que el documento pertenezca a un notebook del usuario. Mientras se completa la eliminación, el documento aparece deshabilitado en la lista. Esta es la única eliminación definitiva que el sistema permite a un usuario (RN-01, RNF-10).

Manejo de errores: Si el usuario cancela la confirmación, el documento se mantiene sin cambios. Si alguna de las eliminaciones falla, el documento permanece en la lista del notebook y el sistema informa el error.

Estado actual: la eliminación se ejecuta sin solicitar confirmación, y si falla, el sistema no lo informa al usuario.

Salida: **En caso de éxito:** Documento eliminado por completo de las tres capas de almacenamiento, sin que vuelva a aparecer en consultas, en las respuestas del chat del notebook ni en su listado.

En caso de error: Documento sin cambios, que permanece en la lista, con un mensaje que informa el error.

Prioridad: Media **Estado:** Parcial

Trazabilidad: Historias de usuario HU-19 · Casos de uso CU-13

Módulo 6: Búsqueda de Temas Similares

RF-20 — Búsqueda por similitud

Descripción: El usuario puede buscar los temas más parecidos a uno de referencia desde "Temas Similares", eligiendo entre dos modos: por tema de referencia o por descripción en texto libre. El sistema compara los vectores del tema o del texto de referencia contra el resto de la base vectorial y calcula un porcentaje de similitud para cada resultado.

Reglas y validaciones: El criterio de búsqueda no puede estar vacío. El sistema conserva hasta 30 resultados con una similitud de al menos 30%, los ordena de mayor a menor y los clasifica como Alta (90% o más), Media (de 70% a 89%) o Baja (menos de 70%); para cada resultado muestra el nombre del tema, sus datos descriptivos y su porcentaje, junto con el tiempo que tomó la búsqueda y la precisión promedio. Sobre cualquier resultado, el usuario puede solicitar al modelo de lenguaje local

un resumen del tema, sus palabras clave, los factores de similitud con la referencia y una conclusión, o descargar sus documentos. Cada búsqueda se registra en la bitácora (RF-21) con su modo, su criterio, el total de resultados y el tiempo empleado.

Manejo de errores: Si el criterio está vacío, el sistema no ejecuta la búsqueda y solicita completarlo; si ningún tema supera el umbral, la lista de resultados queda vacía; si la búsqueda o la generación del resumen fallan, el sistema muestra un mensaje de error.

Estado actual: la búsqueda por tema de referencia acepta únicamente identificadores con el formato heredado del proyecto Justicia (ver RT-06), y la opción del menú todavía se llama "Casos Similares".

Salida: En caso de éxito: Listado de hasta 30 temas o documentos similares al de referencia, ordenados de mayor a menor grado de coincidencia, con el porcentaje de similitud y su clasificación visibles para cada resultado; resumen generado por IA bajo demanda.

En caso de error: Mensaje que indica el problema —criterio vacío o fallo de la búsqueda o del resumen—, o lista vacía cuando ningún tema supera el umbral.

Prioridad: Media **Estado:** Parcial

Trazabilidad: Historias de usuario HU-20 · Casos de uso CU-14

Módulo 7: Bitácora y Reportes

RF-21 — Registro automático de acciones

Descripción: El sistema registra de forma automática, inmediata y sin intervención manual, cualquier operación significativa realizada por un usuario: inicios de sesión (exitosos y fallidos) y cierres de sesión, los pasos de la recuperación de contraseña, las operaciones sobre cuentas de usuario, las cargas de archivo, las consultas al asistente, las búsquedas de temas similares y las exportaciones de la bitácora.

Contenido del registro: Cada registro incluye, como mínimo, el usuario que ejecutó la acción, la fecha y hora exacta, el tipo de acción, una descripción y el tema asociado cuando aplique, además de información adicional propia de cada tipo de acción; por ejemplo, el motivo de un inicio de sesión fallido, los campos modificados en una edición de usuario, el identificador y el número de fragmentos de un documento cargado, o el modo, el criterio y el total de resultados de una búsqueda.

Reglas y validaciones: Los registros de bitácora son inmutables: el sistema no expone ninguna función para editarlos ni eliminarlos, ni siquiera al Administrador. El registro no debe interrumpir la acción del usuario: si el registro de una acción falla, la acción se completa de todas formas.

Salida: Resultado: Un registro de bitácora nuevo e inmutable por cada acción relevante, disponible de inmediato para su consulta (RF-22) y para el dashboard de métricas (RF-23).

Prioridad: Alta **Estado:** Implementado

Trazabilidad: Historias de usuario HU-21, HU-24, HU-25 · Casos de uso CU-01, CU-02, CU-04, CU-05, CU-07, CU-09, CU-14, CU-15

RF-22 — Consulta y filtrado de la bitácora

Descripción: Los administradores pueden consultar la bitácora completa del sistema desde "Historial de Actividades", en una tabla que muestra, para cada registro, la fecha y hora, el usuario, el tipo de acción, el tema asociado y una descripción.

Filtros: Los resultados pueden filtrarse por usuario (nombre, apellido o correo), tema, tipo de acción y rango de fechas (fecha de inicio y fecha de fin), de forma combinable: el listado muestra solo los registros que cumplen todos los filtros a la vez.

Detalle y exportación: El Administrador puede abrir el detalle de cualquier registro para ver su información adicional (RF-21), y exportar a PDF todos los registros que cumplen los filtros vigentes, hasta un máximo de 100 000; la exportación también queda registrada en la bitácora.

Manejo de errores: Si ningún registro cumple los filtros, la tabla indica que no se encontraron registros; si no hay registros para exportar, el sistema lo informa y no genera el documento.

Salida: En caso de éxito: Listado de los registros que cumplen simultáneamente todos los criterios seleccionados; documento PDF con esos registros cuando se solicita la exportación, con un mensaje que indica cuántos registros incluye.

Sin resultados: Aviso de que no se encontraron registros o de que no hay registros para exportar.

Prioridad: Alta **Estado:** Implementado

Trazabilidad: Historias de usuario HU-22 · Casos de uso CU-15

RF-23 — Dashboard de métricas

Descripción: El sistema presenta, solo para administradores, un panel visual con indicadores clave sobre el uso del sistema, en la pestaña "Estadísticas" de "Historial de Actividades". Los indicadores se calculan a partir de la bitácora vigente al momento de la consulta.

Indicadores: Tarjetas con los registros del día, los eventos de los últimos 30 días, los usuarios activos, la cantidad de temas registrados y las consultas al chat; y gráficos con la distribución de acciones por tipo, la actividad diaria de los últimos 7 días, los 5 usuarios más activos, la distribución de las consultas del chat entre generales y acotadas a un tema, los 5 temas más consultados y la distribución de tipos de archivo cargados.

Manejo de errores: Si no hay datos suficientes para un indicador, el panel lo indica en lugar de mostrar un gráfico vacío.

Salida: Resultado: Panel visual con tarjetas de estadísticas y gráficos, actualizado con los datos vigentes al momento de la consulta.

Prioridad: Baja **Estado:** Implementado

Trazabilidad: Historias de usuario HU-23 · Casos de uso CU-16

3.2 Requisitos No Funcionales

Eficiencia

RNF-01 — Manejo de solicitudes concurrentes

Descripción: El backend, construido sobre FastAPI de forma asíncrona, debe atender múltiples solicitudes de distintos usuarios de forma concurrente sin bloquear el procesamiento de unas por otras, particularmente durante la generación de respuestas del asistente en streaming, que son operaciones de larga duración.

Salida: Tiempos de respuesta que no se degradan de forma perceptible al aumentar el número de usuarios conectados simultáneamente, dentro de la capacidad de la infraestructura local disponible.

Prioridad: Alta **Estado:** **Implementado**

Trazabilidad: Historias de usuario HU-11, HU-16 · Casos de uso CU-09, CU-10

RNF-02 — Procesamiento asíncrono de la ingesta

Descripción: La carga de un archivo debe responder de inmediato al usuario (confirmando que la carga fue aceptada) sin esperar a que termine el procesamiento completo, delegando la extracción, el reconocimiento y la vectorización a un worker en segundo plano (Celery), con seguimiento de progreso consultable por el usuario mientras tanto.

Salida: Confirmación de carga aceptada en segundos, independientemente de cuánto tarde el procesamiento completo del archivo en segundo plano.

Prioridad: Alta **Estado:** **Implementado**

Trazabilidad: Historias de usuario HU-05, HU-07 · Casos de uso CU-07, CU-08

Usabilidad

RNF-03 — Interfaz clara y con retroalimentación visible

Descripción: La interfaz debe ofrecer flujos claros para las tareas principales (carga de archivos, consulta al asistente, búsqueda de temas similares), con mensajes de retroalimentación explícitos para los estados de éxito, error y validación de datos —nunca dejar una acción sin ninguna respuesta visual para el usuario.

Salida: Mensaje visible y comprensible ante cada resultado posible de una acción del usuario (éxito, error específico, validación pendiente).

Prioridad: Alta **Estado:** **Implementado**

Trazabilidad: Historias de usuario HU-05, HU-07, HU-11, HU-20 · Casos de uso CU-07, CU-09, CU-14

RNF-04 — Diseño adaptable (responsive)

Descripción: La interfaz debe adaptarse correctamente a distintos tamaños de pantalla, priorizando el uso desde computadoras de escritorio institucionales como caso principal, sin romper su funcionalidad en pantallas más pequeñas.

Salida: Interfaz funcional y legible en resoluciones de escritorio estándar, sin elementos superpuestos ni inaccesibles.

Prioridad: Media **Estado:** **Implementado**

Trazabilidad: Requisito transversal: aplica a todas las historias de usuario (HU-01 a HU-25) y a todos los casos de uso (CU-01 a CU-16)

Compatibilidad

RNF-05 — Compatibilidad con navegadores modernos

Descripción: El sistema debe funcionar correctamente en los navegadores web modernos de mayor uso institucional (Chrome, Firefox y Edge en sus versiones vigentes), sin depender de funciones exclusivas de un solo navegador.

Salida: Funcionalidad completa e idéntica del sistema en cualquiera de los tres navegadores soportados.

Prioridad: Alta **Estado:** **Implementado**

Trazabilidad: Requisito transversal: aplica a todas las historias de usuario (HU-01 a HU-25) y a todos los casos de uso (CU-01 a CU-16)

RNF-06 — Despliegue mediante contenedores

Descripción: El sistema completo (backend, frontend y todos sus servicios de apoyo) debe poder desplegarse mediante Docker Compose en cualquier equipo que cumpla los requisitos de hardware, sin pasos de instalación manual adicionales más allá de la configuración de variables de entorno.

Salida: Los ocho servicios del sistema levantados y comunicándose correctamente entre sí tras ejecutar el comando de despliegue estándar.

Prioridad: Alta **Estado:** **Implementado**

Trazabilidad: Requisito transversal: aplica a todas las historias de usuario (HU-01 a HU-25) y a todos los casos de uso (CU-01 a CU-16)

Seguridad

RNF-07 — Autenticación y autorización basada en tokens

Descripción: Toda comunicación entre el frontend y la API del backend debe ir autenticada mediante un token JWT firmado, con verificación de rol en cada endpoint protegido (ver RF-02). El sistema no debe exponer ninguna función sensible (ingesta, consulta, gestión de usuarios, bitácora) sin autenticación válida.

Salida: Rechazo uniforme de cualquier solicitud sin un token JWT válido y vigente, independientemente del endpoint solicitado.

Prioridad: Alta **Estado:** **Implementado**

Trazabilidad: Historias de usuario HU-01, HU-02, HU-24 · Casos de uso CU-01, CU-02, CU-03

RNF-08 — Cifrado de datos sensibles y política de contraseñas

Descripción: Las contraseñas de los usuarios deben almacenarse siempre cifradas mediante un algoritmo de hash con sal, nunca en texto plano ni de forma reversible, y toda contraseña definida por un usuario debe tener al menos 8 caracteres. La comunicación entre el navegador y el backend debe protegerse mediante HTTPS/TLS en cualquier entorno expuesto más allá de desarrollo local. Estado actual: la interfaz exige 8 caracteres, pero el servidor todavía acepta contraseñas desde 6.

Salida: Imposibilidad de recuperar una contraseña de usuario en texto plano a partir de la base de datos, incluso con acceso directo a ella; rechazo de cualquier contraseña de menos de 8 caracteres, tanto en la interfaz como en el servidor.

Prioridad: Alta **Estado:** Parcial

Trazabilidad: Historias de usuario HU-01, HU-03, HU-04, HU-25 · Casos de uso CU-01, CU-04, CU-05, CU-06

RNF-09 — Procesamiento 100% local de la información

Descripción: Ningún documento, consulta ni respuesta del asistente debe transmitirse a un servicio de inteligencia artificial en la nube; todo el procesamiento —extracción, reconocimiento, vectorización, generación de respuestas— debe ejecutarse dentro de la infraestructura local del sistema (ver RT-02).

Salida: Cero solicitudes salientes hacia servicios de IA externos durante el uso normal del sistema, verificable por el tráfico de red generado.

Prioridad: Alta **Estado:** Implementado

Trazabilidad: Historias de usuario HU-08, HU-09, HU-11, HU-12, HU-20 · Casos de uso CU-07, CU-08, CU-09, CU-14

Disponibilidad y Confiabilidad

RNF-10 — Integridad y no eliminación física de datos

Descripción: El sistema no debe ofrecer ninguna función que elimine físicamente un registro de tema, documento, usuario o bitácora; toda gestión de baja se realiza mediante cambios de estado (por ejemplo, Activo/Inactivo), preservando el historial completo para fines de auditoría. La única excepción son los documentos que un usuario carga en sus propios notebooks, que puede quitar de forma definitiva (RF-19).

Salida: Persistencia permanente de todo registro creado en el sistema, incluso tras ser marcado como inactivo o eliminado desde la perspectiva del usuario, salvo la excepción de los documentos de notebooks.

Prioridad: Alta **Estado:** Implementado

Trazabilidad: Historias de usuario HU-19, HU-21, HU-25 · Casos de uso CU-05, CU-13, CU-15

RNF-11 — Recuperación ante fallos de arranque de servicios

Descripción: Si un servicio dependiente (como la base de datos relacional) no está disponible en el momento en que otro servicio arranca, este último debe reintentar la conexión de forma automática

durante un período razonable, en vez de fallar de forma permanente y requerir un reinicio manual del contenedor.

Salida: Recuperación automática del servicio afectado dentro de la ventana de reintento definida, sin intervención manual, cuando la dependencia vuelve a estar disponible.

Prioridad: Media **Estado:** **Implementado**

Trazabilidad: Requisito transversal: aplica a todas las historias de usuario (HU-01 a HU-25) y a todos los casos de uso (CU-01 a CU-16)

4. Apéndices

4.1 Matriz de trazabilidad

Las siguientes matrices relacionan cada requisito con las historias de usuario (documento "Historias de Usuario - ServIA") y los casos de uso (documento "Casos de Uso - ServIA") que lo desarrollan o en los que aplica.

Requisitos funcionales

RF	Requisito funcional	Historias de usuario	Casos de uso
RF-01	Autenticación y cierre de sesión	HU-01, HU-24	CU-01, CU-02
RF-02	Gestión de roles y usuarios	HU-02, HU-25	CU-03, CU-05
RF-03	Recuperación de contraseña	HU-03, HU-25	CU-04, CU-05
RF-04	Perfil de usuario (avatar y contraseña)	HU-04	CU-06
RF-05	Carga de archivos multiformato	HU-05	CU-07
RF-06	Asociación a un tema	HU-06	CU-07
RF-07	Procesamiento automatizado del contenido	HU-07	CU-07
RF-08	Vectorización y almacenamiento semántico	HU-08	CU-07
RF-09	Reconocimiento de texto en imagen	HU-09	CU-08
RF-10	Limitación de reconocimiento de manuscrito (cursivo y de imprenta)	HU-10	CU-08
RF-11	Consulta en lenguaje natural	HU-11	CU-09
RF-12	Respuestas con cita de fuente y sin invención de información	HU-12	CU-09

RF	Requisito funcional	Historias de usuario	Casos de uso
RF-13	Búsqueda híbrida por tema	HU-13	CU-09
RF-14	Persistencia del historial de conversación	HU-14	CU-09
RF-15	Copiar y reintentar respuesta	HU-15	CU-10
RF-16	Recuperación ante corte de conexión durante el streaming	HU-16	CU-09
RF-17	Creación de notebooks	HU-17	CU-11
RF-18	Previsualización de archivos originales	HU-18	CU-12
RF-19	Eliminación de documentos del notebook	HU-19	CU-13
RF-20	Búsqueda por similitud	HU-20	CU-14
RF-21	Registro automático de acciones	HU-21, HU-24, HU-25	CU-01, CU-02, CU-04, CU-05, CU-07, CU-09, CU-14, CU-15
RF-22	Consulta y filtrado de la bitácora	HU-22	CU-15
RF-23	Dashboard de métricas	HU-23	CU-16

Requisitos no funcionales

RNF	Requisito no funcional	Historias de usuario	Casos de uso
RNF-01	Manejo de solicitudes concurrentes	HU-11, HU-16	CU-09, CU-10
RNF-02	Procesamiento asíncrono de la ingesta	HU-05, HU-07	CU-07, CU-08
RNF-03	Interfaz clara y con retroalimentación visible	HU-05, HU-07, HU-11, HU-20	CU-07, CU-09, CU-14
RNF-04	Diseño adaptable (responsive)	Todas (transversal)	Todos (transversal)
RNF-05	Compatibilidad con navegadores modernos	Todas (transversal)	Todos (transversal)
RNF-06	Despliegue mediante contenedores	Todas (transversal)	Todos (transversal)
RNF-07	Autenticación y autorización basada en tokens	HU-01, HU-02, HU-24	CU-01, CU-02, CU-03
RNF-08	Cifrado de datos sensibles y política de contraseñas	HU-01, HU-03, HU-04, HU-25	CU-01, CU-04, CU-05, CU-06

RNF	Requisito no funcional	Historias de usuario	Casos de uso
RNF-09	Procesamiento 100% local de la información	HU-08, HU-09, HU-11, HU-12, HU-20	CU-07, CU-08, CU-09, CU-14
RNF-10	Integridad y no eliminación física de datos	HU-19, HU-21, HU-25	CU-05, CU-13, CU-15
RNF-11	Recuperación ante fallos de arranque de servicios	Todas (transversal)	Todos (transversal)